

UJIAN TENGAH SEMESTER
ANALITIK VISUALISASI DATA
IMDB TOP 1000



Disusun oleh:

Az-Zahra Imsawati Sugianto

2509116062

Program Studi Sistem Informasi

Fakultas Teknik

Universitas Mulawarman

2026

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR GAMBAR	iii
BAB I PENDAHULUAN	4
1.1 Latar Belakang	4
1.2 Tujuan Analisi	5
BAB II PEMBAHASAN	6
2.1 Buseinness Understanding	6
2.1.1 Business Objective	6
2.1.2 Assess Situation.....	6
2.1.3 Analytic Goal & Project Plan	7
2.2 Data Understanding & EDA	7
2.2.1 Import Library	8
2.2.2 Memuat Dataset	8
2.2.3 Deskripsi Data	9
2.2.4 Verifikasi Kualitas Data.....	14
2.2.5 Eksplorasi Data (EDA).....	29
2.3 Data Preparation.....	35
2.3.1 Data Type	35
2.3.2 Inconsistent Values.....	39
2.3.3 Missing Values	40
2.3.4 Duplicated Values	44
2.3.5 Outliers.....	44
2.3.6 Data Construction.....	47
2.3.7 Data Reduction.....	48
BAB III PENUTUP	50
3.1 Kesimpulan	50
3.2 Saran	50

DAFTAR GAMBAR

Gambar 1 Memuat Dataset	9
Gambar 2 Informasi Dataset	10
Gambar 3 Statistik Deskriptif	12
Gambar 4 Released Year	14
Gambar 5 Insert Link	15
Gambar 6 Series Title	16
Gambar 7 Released Year	16
Gambar 8 Certificate	17
Gambar 9 Runtime	17
Gambar 10 Genre	18
Gambar 11 IMDb Rating	18
Gambar 12 Overview	19
Gambar 13 Meta score	19
Gambar 14 Director	20
Gambar 15 Star 1	20
Gambar 16 Star 2	21
Gambar 17 Star 3	22
Gambar 18 Star 4	22
Gambar 19 No of Votes	23
Gambar 20 Gross	23
Gambar 21 Missing Values	24
Gambar 22 Duplicated Values	25
Gambar 23 Outliers	26
Gambar 24 Boxplot No of Votes	27
Gambar 25 Boxplot IMDb Rating	28
Gambar 26 Boxplot Meta Score	29
Gambar 27 Comparison	30
Gambar 28 Composition	32
Gambar 29 Distribution	33
Gambar 30 Relation	34
Gambar 31 Data Type	36
Gambar 32 Data Type Released Year	37
Gambar 33 Data Type Runtime	38
Gambar 34 Data Type Gross	39
Gambar 35 Inconsistent Values Certificate	40
Gambar 36 Missing Values	41
Gambar 37 Distribusi Gross	42
Gambar 38 Distribusi Meta Score	43
Gambar 39 Outliers	45
Gambar 40 Tampilan Dataset	47
Gambar 41 After Data Reduction	49

BAB I

PENDAHULUAN

1.1 Latar Belakang

Industri perfilman merupakan salah satu sektor hiburan yang terus berkembang dan memiliki tingkat persaingan yang tinggi. Setiap tahunnya, berbagai film dan acara televisi diproduksi dengan berbagai genre, konsep cerita, serta karakter pemain yang berbeda. Banyaknya pilihan tontonan membuat perusahaan film perlu memahami preferensi penonton agar dapat menghasilkan karya yang menarik, berkualitas, serta mampu bersaing di pasar hiburan. Oleh karena itu, pemahaman terhadap faktor-faktor yang memengaruhi keberhasilan sebuah film menjadi hal yang penting bagi industri perfilman.

Salah satu sumber informasi yang dapat digunakan untuk memahami preferensi penonton adalah data yang tersedia pada platform IMDb (Internet Movie Database). Platform ini menyediakan berbagai informasi terkait film dan acara televisi, seperti judul film, genre, tahun rilis, durasi tayang, rating dari penonton, jumlah voting, serta tokoh atau pemain yang terlibat dalam film tersebut. Dataset IMDb Top 1000 Movies merupakan kumpulan data yang berisi 1000 film dan acara TV terbaik berdasarkan rating IMDb, sehingga dataset ini merepresentasikan film-film dengan tingkat kualitas dan popularitas yang tinggi menurut penilaian publik.

Meskipun data mengenai film dan penilaian penonton tersedia dalam jumlah yang cukup besar, pemanfaatan data tersebut untuk menggali pola preferensi penonton masih belum dilakukan secara optimal. Banyak keputusan dalam proses produksi film, seperti pemilihan genre, durasi film, maupun pemilihan pemain, masih sering didasarkan pada tren umum atau intuisi industri tanpa didukung oleh analisis data yang mendalam. Hal ini menyebabkan peluang untuk memahami pola kesukaan penonton secara lebih sistematis menjadi kurang dimanfaatkan.

Beberapa aspek yang dapat dianalisis dari dataset tersebut antara lain adalah hubungan antara genre film dengan tingkat rating yang diperoleh, pengaruh durasi film terhadap penilaian penonton, serta keterkaitan antara jumlah voting dengan tingkat popularitas film. Selain itu, peran tokoh atau pemain film juga dapat dianalisis untuk mengetahui apakah aktor tertentu sering muncul dalam film dengan rating tinggi atau memiliki pengaruh terhadap popularitas film. Analisis terhadap berbagai faktor tersebut dapat membantu mengidentifikasi karakteristik film yang cenderung mendapatkan respon positif dari penonton.

Melalui pendekatan analitik dan visualisasi data, dataset IMDb Top 1000 dapat dimanfaatkan untuk menemukan pola serta hubungan antar variabel yang terdapat dalam data film. Hasil analisis ini diharapkan dapat memberikan gambaran yang lebih jelas mengenai preferensi penonton terhadap berbagai karakteristik film, seperti genre yang paling diminati, durasi film yang cenderung mendapatkan rating tinggi, serta faktor lain yang memengaruhi popularitas film.

Dengan demikian, analisis data ini memiliki peran penting dalam mendukung pengambilan keputusan yang lebih berbasis data dalam industri perfilman. Informasi yang dihasilkan dari analisis ini dapat digunakan sebagai bahan pertimbangan dalam menentukan konsep cerita, memilih pemain yang sesuai, serta menyusun strategi produksi film yang lebih efektif dan sesuai dengan preferensi pasar.

1.2 Tujuan

Berdasarkan latar belakang yang telah dijelaskan, tujuan dari analisis data ini adalah untuk memahami faktor-faktor yang memengaruhi rating dan popularitas film berdasarkan dataset IMDb Top 1000 Movies yang diperoleh dari platform Kaggle dan bersumber dari IMDb. Secara lebih rinci, tujuan dari analisis ini adalah sebagai berikut:

1. Mengidentifikasi hubungan antara genre film, durasi tayang, dan tahun rilis dengan rating IMDb untuk mengetahui faktor yang memengaruhi kualitas penilaian film.
2. Menganalisis jumlah voting penonton sebagai indikator tingkat popularitas film.
3. Mengetahui karakteristik film yang cenderung memiliki rating tinggi dan tingkat popularitas besar berdasarkan data yang tersedia.
4. Menganalisis peran tokoh atau pemain film dalam kaitannya dengan performa rating film.
5. Menyajikan hasil analisis dalam bentuk visualisasi data sehingga pola dan hubungan antar variabel dapat dipahami dengan lebih mudah

BAB II

PEMBAHASAN

2.1 Buseiness Understanding

Business Understanding merupakan tahap awal dalam proses analisis data yang bertujuan untuk memahami permasalahan, konteks analisis, serta tujuan yang ingin dicapai melalui pemanfaatan data. Pada tahap ini dilakukan identifikasi terhadap kebutuhan analisis dan peluang yang dapat diperoleh dari data yang tersedia. Dalam penelitian ini, tahap Business Understanding digunakan untuk memahami bagaimana data film yang bersumber dari IMDb dan diperoleh melalui platform Kaggle dapat dimanfaatkan untuk menganalisis faktor-faktor yang memengaruhi rating dan popularitas film. Tahap ini meliputi beberapa bagian, yaitu *Business Objective*, *Assess Situation*, serta *Analytic Goal and Project Plan*.

2.1.1 Business Objective

Data ini merupakan sebuah data yang berisi 1000 film dan acara TV terbaik berdasarkan rating IMDb, yang mencakup informasi seperti judul, genre, tahun rilis, durasi, rating, jumlah voting dari penonton, serta tokoh atau pemain film. Data ini mempresentasikan karya hiburan dengan tingkat popularitas dan kualitas yang tinggi menurut penilaian publik.

Permasalahan yang muncul adalah belum optimalnya pemanfaatan data dalam menganalisis pola kesukaan penonton, seperti genre yang paling disukai, durasi film yang cenderung mendapatkan rating tinggi, peran pemain film terhadap performa rating, serta karakteristik film yang memiliki tingkat popularitas besar. Banyak keputusan produksi masih didasarkan pada tren umum tanpa analisis data yang mendalam.

Analisis ini bertujuan agar industri perfilman dapat memperoleh gambaran yang jelas mengenai preferensi penonton sehingga dapat digunakan sebagai bahan pertimbangan dalam membuat film, menentukan konsep cerita, memilih pemain yang sesuai, serta menyusun strategi produksi yang lebih tepat dan berbasis data.

2.1.2 Assess Situation

Dunia perfilman terus berkembang dengan semakin banyaknya film dan acara TV yang diproduksi setiap tahun, sehingga persaingan kualitas hiburan semakin tinggi. Di tengah banyaknya pilihan tontonan, perusahaan film perlu memahami jenis film yang

paling disukai penonton agar dapat menghasilkan karya yang sesuai dengan kebutuhan pasar.

Dataset IMDb Top 1000 menyediakan data penilaian penonton terhadap film dan serial terbaik melalui rating dan jumlah voting, serta dilengkapi dengan informasi genre, durasi, tahun rilis dan tokoh atau pemain film. Namun, data tersebut masih belum dimanfaatkan secara maksimal untuk menggali pola preferensi penonton secara mendalam.

Melalui analisis data ini, industri perfilman memiliki peluang untuk memperoleh wawasan mengenai karakteristik film yang diminati pasar, sehingga dapat mendukung pengambilan keputusan produksi dan strategi bisnis yang lebih tepat.

2.1.3 Analytic Goal & Project Plan

Untuk mencapai tujuan analisis, dilakukan beberapa tahapan pengolahan dan analisis data sebagai berikut:

1. Pengumpulan, pembersihan, dan eksplorasi data film berdasarkan dataset yang tersedia.
2. Mengidentifikasi pola hubungan antara genre film, durasi tayang, tahun rilis, dan rating IMDb untuk memahami faktor yang memengaruhi kualitas film.
3. Menganalisis preferensi penonton berdasarkan jumlah voting serta karakteristik film yang diminati pasar.
4. Menganalisis peran tokoh atau pemain film terhadap performa rating, seperti aktor yang sering muncul dalam film dengan rating tinggi.
5. Menyusun visualisasi data dan insight berbasis data untuk membantu industri perfilman dalam perencanaan produksi dan strategi konten.

2.2 Data Understanding & EDA

Pada tahap ini dilakukan proses Data Understanding dan Exploratory Data Analysis (EDA) untuk memahami karakteristik dataset yang digunakan. Data understanding bertujuan untuk mengenali struktur data, tipe data pada setiap kolom, serta informasi penting yang terdapat dalam dataset. Selanjutnya dilakukan EDA untuk mengeksplorasi data melalui berbagai teknik analisis dan visualisasi guna mengetahui pola, distribusi data, hubungan antar variabel, serta menemukan insight awal yang dapat mendukung proses analisis selanjutnya.

2.2.1 Import Library

Import library merupakan langkah awal dalam proses pengolahan data di Python yang digunakan untuk memanggil pustaka atau modul yang dibutuhkan. Library ini menyediakan berbagai fungsi yang membantu dalam proses pengolahan, analisis, dan visualisasi data.

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import seaborn as sns
```

Perintah ini digunakan untuk mengimpor beberapa library yang diperlukan dalam proses analisis dan visualisasi data. Library pandas digunakan untuk mengolah dan memanipulasi data dalam bentuk DataFrame, sedangkan seaborn dan matplotlib.pyplot digunakan untuk membuat berbagai jenis visualisasi data seperti grafik dan plot.

2.2.2 Memuat Dataset

Dataset merupakan kumpulan data yang digunakan dalam proses analisis. Pada tahap ini, dataset dimuat ke dalam sistem agar dapat diolah dan dianalisis lebih lanjut. Proses ini penting untuk memastikan bahwa data telah terbaca dengan benar dan siap digunakan pada tahap berikutnya.

```
file = '/content/drive/MyDrive/AVD/imdb_top_1000.csv'
df = pd.read_csv(file)

df
```

Perintah ini digunakan untuk membaca dataset imdb_top_1000.csv dari lokasi penyimpanan di Google Drive menggunakan fungsi read_csv() dari pandas, kemudian menyimpannya ke dalam variabel df sebagai DataFrame. Setelah itu, perintah df digunakan untuk menampilkan isi dataset sehingga dapat dilihat dan dianalisis lebih lanjut.


```
df.info()

*** <class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 16 columns):
#   Column          Non-Null Count  Dtype
---  ---
0   Poster_Link     1000 non-null   object
1   Series_Title    1000 non-null   object
2   Released_Year   1000 non-null   object
3   Certificate      899 non-null    object
4   Runtime         1000 non-null   object
5   Genre           1000 non-null   object
6   IMDB_Rating     1000 non-null   float64
7   Overview        1000 non-null   object
8   Meta_score      843 non-null    float64
9   Director        1000 non-null   object
10  Star1           1000 non-null   object
11  Star2           1000 non-null   object
12  Star3           1000 non-null   object
13  Star4           1000 non-null   object
14  No_of_Votes     1000 non-null   int64
15  Gross           831 non-null    object
dtypes: float64(2), int64(1), object(13)
memory usage: 125.1+ KB
```

Gambar 2 Informasi Dataset

Berdasarkan output yang ditampilkan, dataset terdiri dari sekitar 1000 data film dengan beberapa kolom yang berisi informasi seperti judul film, genre, tahun rilis, rating IMDb, dan jumlah voting penonton. Informasi ini membantu memahami struktur dataset sebelum dilakukan analisis lebih lanjut.

2. Informasi Lanjutan

Untuk memahami karakteristik *dataset* secara lebih mendalam, bagian ini menyajikan detail atribut yang terdapat dalam tabel data. Rincian mengenai jumlah entri, tipe variabel, dan fungsi masing-masing kolom dipaparkan sebagai berikut:

1. Poster_Link Jumlah baris: 1000 Tipe data: object Deskripsi: Link atau URL poster film.
2. Series_Title Jumlah baris: 1000 Tipe data: object Deskripsi: Judul film atau serial.
3. Released_Year Jumlah baris: 1000 Tipe data: object Deskripsi: Tahun rilis film atau serial.
4. Certificate Jumlah baris: 899 Tipe data: object Deskripsi: Klasifikasi usia atau rating penonton (misalnya PG-13, R, dll).
5. Runtime Jumlah baris: 1000 Tipe data: object Deskripsi: Durasi film dalam satuan menit.

6. Genre Jumlah baris: 1000 Tipe data: object Deskripsi: Genre atau kategori film (misalnya Drama, Action, Comedy, dll).
7. IMDB_Rating Jumlah baris: 1000 Tipe data: float64 Deskripsi: Nilai rating film berdasarkan penilaian pengguna IMDb.
8. Overview Jumlah baris: 1000 Tipe data: object Deskripsi: Ringkasan atau sinopsis singkat cerita film.
9. Meta_score Jumlah baris: 843 Tipe data: float64 Deskripsi: Skor penilaian dari kritikus film (Metascore).
10. Director Jumlah baris: 1000 Tipe data: object Deskripsi: Nama sutradara film.
11. Star1 Jumlah baris: 1000 Tipe data: object Deskripsi: Pemeran utama pertama dalam film.
12. Star2 Jumlah baris: 1000 Tipe data: object Deskripsi: Pemeran utama kedua dalam film.
13. Star3 Jumlah baris: 1000 Tipe data: object Deskripsi: Pemeran utama ketiga dalam film.
14. Star4 Jumlah baris: 1000 Tipe data: object Deskripsi: Pemeran utama keempat dalam film.
15. No_of_Votes Jumlah baris: 1000 Tipe data: int64 Deskripsi: Jumlah voting atau suara yang diberikan oleh pengguna IMDb.
16. Gross Jumlah baris: 831 Tipe data: object Deskripsi: Pendapatan kotor film (box office).

3. Informasi Statistik Deskriptif

```
df.describe(include='all')
```

Perintah `df.describe(include='all')` digunakan untuk menampilkan ringkasan statistik dari seluruh kolom pada dataset menggunakan library Pandas di Python. Perintah ini menampilkan informasi seperti jumlah data, nilai unik, nilai yang paling sering muncul, serta statistik numerik seperti rata-rata, nilai minimum, dan maksimum.

df.describe(include="all")																			
	Poster_Link	Series_Title	Released_Year	Certificate	Runtime	Genre	IMDB_Rating	Overview	Meta_score	Director	Star1	Star2	Star3	Star4	No_of_Votes	Gross			
count	1000	1000	1000	899	1000	1000	1000.000000	1000	843.000000	1000	1000	1000	1000	1000	1.000000e+03	831			
unique	1000	595	100	15	140	202	NaN	1000	NaN	548	650	841	851	939	1000	NaN			
top		Drishyam	2014	U	100 min	Drama	NaN	A man in London tries to help a counter-espion...	NaN	Alfred Hitchcock	Tom Hanks	Emma Watson	Rupert Grint	Michael Caine	NaN	4,360,000			
freq	1	2	32	234	23	65	NaN	1	NaN	14	12	7	5	4	NaN	5			
mean	NaN	NaN	NaN	NaN	NaN	NaN	7.949300	NaN	77.971530	NaN	NaN	NaN	NaN	NaN	2.736929e+05	NaN			
std	NaN	NaN	NaN	NaN	NaN	NaN	0.275491	NaN	12.375099	NaN	NaN	NaN	NaN	NaN	3.273727e+05	NaN			
min	NaN	NaN	NaN	NaN	NaN	NaN	7.600000	NaN	36.000000	NaN	NaN	NaN	NaN	NaN	2.506800e+04	NaN			
25%	NaN	NaN	NaN	NaN	NaN	NaN	7.700000	NaN	75.000000	NaN	NaN	NaN	NaN	NaN	5.652626e+04	NaN			
50%	NaN	NaN	NaN	NaN	NaN	NaN	7.900000	NaN	78.000000	NaN	NaN	NaN	NaN	NaN	1.355455e+05	NaN			
75%	NaN	NaN	NaN	NaN	NaN	NaN	8.100000	NaN	87.000000	NaN	NaN	NaN	NaN	NaN	3.741612e+05	NaN			
max	NaN	NaN	NaN	NaN	NaN	NaN	9.300000	NaN	100.000000	NaN	NaN	NaN	NaN	NaN	2.363110e+06	NaN			

Gambar 3 Statistik Deskriptif

a. Count (Kelengkapan Data)

Berdasarkan dataset, total data film adalah 1000 baris. Maka dapat disimpulkan:

- Certificate hilang 101 data (1000 - 899)
- Meta_score hilang 157 data (1000 - 843)
- Gross hilang 169 data (1000 - 831)

Kesimpulan: Kolom Certificate, Meta_score, dan Gross mengandung missing values, sementara kolom lainnya sudah lengkap (1000 data).

b. Mean vs Median (Distribusi Data)

- Kolom IMDB_Rating
 - Mean = 7,95
 - Median = 7,90

Nilai rata-rata sedikit lebih besar dari median, menunjukkan distribusi rating relatif stabil dan hampir simetris. Artinya, mayoritas film dalam dataset memiliki kualitas tinggi dengan rating yang tidak terlalu bervariasi ekstrem.

- Kolom Meta_score
 - Mean = 77,97
 - Median = 79,00

Median sedikit lebih besar dari mean, menunjukkan adanya beberapa film dengan skor kritikus rendah yang menurunkan nilai rata-rata.

- Kolom No_of_Votes
 - Mean = 273.692
 - Median = 138.548

Perbedaan yang cukup besar antara mean dan median menunjukkan adanya beberapa film dengan jumlah voting sangat tinggi yang menarik rata-rata ke atas.

Kesimpulan: Secara keseluruhan, variabel No_of_Votes menunjukkan distribusi right-skewed, sedangkan IMDB_Rating relatif stabil dan mendekati distribusi normal.

c. Min dan Max (Validasi Logika)

- IMDB_Rating
 - Min = 7,6
 - Max = 9,3

Rentang rating cukup sempit, menunjukkan semua film dalam dataset termasuk kategori film dengan kualitas tinggi.

- Meta_score
 - Min = 28
 - Max = 100

Terdapat perbedaan signifikan antara skor terendah dan tertinggi, menunjukkan variasi penilaian kritikus.

- No_of_Votes
 - Min = 25.088
 - Max = 2.343.110

Perbedaan yang sangat besar antara nilai minimum dan maksimum menunjukkan adanya film yang sangat populer dibandingkan yang lain.

Kesimpulan: Rentang nilai voting yang sangat lebar wajar terjadi karena film blockbuster biasanya mendapatkan jutaan suara, sedangkan film lama atau niche memperoleh lebih sedikit voting.

d. Standar Deviasi (Std) – Variabilitas Data

- IMDB_Rating
 - Mean = 7,95
 - Std = 0,27

Standar deviasi yang kecil menunjukkan bahwa rating antar film tidak terlalu jauh berbeda.

- Meta_score
 - Mean = 77,97
 - Std = 12,38

Menunjukkan variasi penilaian kritikus yang cukup besar dibanding rating pengguna.

- No_of_Votes
 - Mean = 273.692
 - Std = 327.372

Nilai standar deviasi yang lebih besar dari mean menunjukkan bahwa tingkat popularitas film sangat bervariasi, dari yang biasa saja hingga sangat populer.

2.2.4 Verifikasi Kualitas Data

Verifikasi kualitas data merupakan proses pemeriksaan data untuk memastikan bahwa data yang digunakan sudah akurat, konsisten, dan lengkap. Tahap ini dilakukan untuk mengidentifikasi adanya kesalahan, nilai yang tidak sesuai, maupun data yang hilang sebelum data digunakan dalam proses analisis.

1. Data Type Check

Data Type Check merupakan proses pemeriksaan tipe data pada setiap kolom dalam dataset untuk memastikan bahwa jenis data sudah sesuai dengan format yang seharusnya. Hal ini dilakukan agar data dapat diproses dan dianalisis dengan benar tanpa menimbulkan kesalahan.

```
df.dtypes
```

Perintah `df.dtypes` digunakan untuk menampilkan tipe data dari setiap kolom yang terdapat dalam DataFrame. Perintah ini membantu pengguna mengetahui jenis data pada tiap kolom, seperti integer, float, atau object, sehingga memudahkan dalam proses pengecekan dan pengolahan data.

```

      0
Poster_Link    object
Series_Title  object
Released_Year  object
Certificate    object
Runtime        object
Genre          object
IMDb_Rating   float64
Overview      object
Meta_score    float64
Director       object
Star1          object
Star2          object
Star3          object
Star4          object
No_of_Votes    int64
Gross          object
dtype: object
```

Gambar 4 Released Year

Dapat dilihat pada gambar di atas, kolom `Released_Year` masih bertipe data object, seharusnya kolom ini bertipe data numerik (integer) karena berisi tahun rilis film. Selain itu, kolom `Runtime` dan `Gross` juga masih bertipe object, padahal seharusnya bertipe numerik agar dapat dilakukan analisis statistik dengan tepat.

Informasi ini membantu memastikan bahwa data yang digunakan memang berisi berbagai film yang akan dianalisis.

```
-- array(['The Shawshank Redemption', 'The Godfather', 'The Dark Knight',
        'The Godfather: Part II', '12 Angry Men',
        'The Lord of the Rings: The Return of the King', 'Pulp Fiction',
        'Schindler's List', 'Inception', 'Fight Club',
        'The Lord of the Rings: The Fellowship of the Ring',
        'Forrest Gump', 'El Encanto, El Encanto, El Encanto',
        'The Lord of the Rings: The Two Towers', 'The Matrix',
        'Goodfellas', 'Star Wars: Episode V - The Empire Strikes Back',
        'One Flew Over the Cuckoo's Nest', 'Hamilton', 'Gisaengchung',
        'Socorrami Potro', 'Interstellar', 'L'Étoile de Noël',
        'Sen to Ojiburo no Hanikawashi', 'Saving Private Ryan',
        'The Green Mile', 'La vita è bella', 'Se7en',
        'The Silence of the Lambs', 'Star Wars', 'Seppuku',
        'Shichinin no samurai', 'It's a Wonderful Life', 'Joker',
        'Whiplash', 'The Intouchables', 'The Prestige', 'The Departed',
        'The Pianist', 'Gladiator', 'American History X',
        'The Usual Suspects', 'Léon', 'The Lion King',
        'Terminator 2: Judgment Day', 'Naniwa Cinema Paradise',
        'Hotaru no hako', 'Back to the Future',
        'Once Upon a Time in the West', 'Psycho', 'Casablanca',
        'Modern Times', 'City Lights', 'Capitaine Corcoran',
        'Kiyoko: The Daughter of War', 'Yikraz Veeha', 'Kiki no na wa.',
        'Dangal', 'Spider-Man: Into the Spider-Verse', 'Avengers: Endgame',
        'Avengers: Infinity War', 'Coco', 'Django Unchained',
        'The Dark Knight Rises', '3 Idiots', 'Taare Zameen Par', 'Halli-E',
        'The Lives of Others', 'Gladiator', 'Hush', 'Monochrome-Hime',
        'Once Upon a Time in America', 'Raiders of the Lost Ark',
        'The Shining', 'Apocalypse Now', 'Alien', 'Anand',
        'Tengoku to jigoku',
        'Dr. Strangelove or: How I Learned to Stop Worrying and Love the Bomb',
        'Witness for the Prosecution', 'Paths of Glory', 'Rear Window',
        'Sunset Blvd.', 'The Great Dictator', '1917', 'Lumbard',
        'Anubhavan', 'Drishyam', 'Jagten', 'Jodaei Nader az Simin',
        'Incendies', 'Miracle in cell 409', 'Baden ve Güler',
        'Inglourious Basterds', 'Eternal Sunshine of the Spotless Mind',
        'Amélie', 'Snatch', 'Equilibrium for a Dream', 'American Beauty',
        'Good Will Hunting', 'Bachchan-ke-asman', 'Toy Story',
```

Gambar 6 Series Title

Dapat dilihat pada gambar di atas, pada kolom Series Title berisi data kategorikal berupa judul film dalam format teks. Berdasarkan hasil pengecekan nilai unik, tidak ditemukan perbedaan tipe data maupun format struktur penulisan. Oleh karena itu, tidak terdapat inconsistent values secara struktural pada kolom ini.

c. Released Year

```
df['Released_Year'].unique()
```

Perintah `df['Released_Year'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom Released_Year menggunakan library Pandas di Python. Kolom ini berisi informasi mengenai tahun rilis dari setiap film dalam dataset.

```
array(['1994', '1972', '2008', '1974', '1957', '2003', '1993', '2010',
        '1999', '2001', '1966', '2002', '1990', '1980', '1975', '2020',
        '2019', '2014', '1998', '1997', '1995', '1991', '1977', '1962',
        '1954', '1946', '2011', '2006', '2000', '1988', '1985', '1968',
        '1960', '1942', '1936', '1931', '2018', '2017', '2016', '2012',
        '2009', '2007', '1984', '1981', '1979', '1971', '1963', '1964',
        '1950', '1940', '2013', '2005', '2004', '1992', '1987', '1986',
        '1983', '1976', '1973', '1965', '1959', '1958', '1952', '1948',
        '1944', '1941', '1927', '1921', '2015', '1996', '1989', '1978',
        '1961', '1955', '1953', '1925', '1924', '1982', '1967', '1951',
        '1949', '1939', '1937', '1934', '1928', '1926', '1920', '1970',
        '1969', '1956', '1947', '1945', '1930', '1938', '1935', '1933',
        '1932', '1922', '1943', 'PG'], dtype=object)
```

Gambar 7 Released Year

Dapat dilihat pada gambar, pada kolom Released Year ditemukan nilai yang tidak sesuai yaitu “PG”. Nilai tersebut tidak merepresentasikan tahun, sehingga termasuk inconsistent value.

d. Certificate

```
df['Certificate'].unique()
```

Perintah `df['Certificate'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom Certificate menggunakan library Pandas di Python. Kolom ini berisi informasi mengenai klasifikasi usia atau rating penonton untuk setiap film.

```
array(['A', 'UA', 'U', 'PG-13', 'R', nan, 'PG', 'G', 'Passed', 'TV-14',  
      '16', 'TV-MA', 'Unrated', 'GP', 'Approved', 'TV-PG', 'U/A'],  
      dtype=object)
```

Gambar 8 Certificate

Dapat dilihat pada gambar, pada kolom ini terdapat variasi format yang berbeda sehingga termasuk inconsistent values.

e. Runtime

```
df['Runtime'].unique()
```

Perintah `df['Runtime'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom Runtime menggunakan library Pandas di Python. Kolom ini berisi informasi mengenai durasi film yang biasanya ditampilkan dalam satuan menit.

```
... array(['142 min', '175 min', '152 min', '202 min', '96 min', '201 min',  
          '154 min', '195 min', '148 min', '139 min', '178 min', '161 min',  
          '179 min', '136 min', '146 min', '124 min', '133 min', '160 min',  
          '132 min', '153 min', '169 min', '130 min', '125 min', '189 min',  
          '116 min', '127 min', '118 min', '121 min', '207 min', '122 min',  
          '106 min', '112 min', '151 min', '150 min', '155 min', '119 min',  
          '110 min', '88 min', '137 min', '89 min', '165 min', '109 min',  
          '102 min', '87 min', '126 min', '147 min', '117 min', '181 min',  
          '149 min', '105 min', '164 min', '170 min', '98 min', '101 min',  
          '113 min', '134 min', '229 min', '115 min', '143 min', '95 min',  
          '104 min', '123 min', '131 min', '108 min', '81 min', '99 min',  
          '114 min', '129 min', '228 min', '128 min', '103 min', '107 min',  
          '68 min', '138 min', '156 min', '167 min', '163 min', '186 min',  
          '321 min', '135 min', '140 min', '180 min', '158 min', '210 min',  
          '86 min', '162 min', '177 min', '204 min', '91 min', '172 min',  
          '45 min', '145 min', '100 min', '196 min', '93 min', '120 min',  
          '92 min', '144 min', '80 min', '183 min', '111 min', '141 min',  
          '224 min', '171 min', '188 min', '94 min', '185 min', '85 min',  
          '205 min', '212 min', '238 min', '72 min', '67 min', '76 min',  
          '159 min', '83 min', '90 min', '84 min', '191 min', '197 min',  
          '174 min', '97 min', '75 min', '157 min', '209 min', '82 min',  
          '220 min', '64 min', '184 min', '168 min', '166 min', '192 min',  
          '194 min', '193 min', '69 min', '70 min', '242 min', '79 min',  
          '71 min', '78 min'], dtype=object)
```

Gambar 9 Runtime

Dapat dilihat pada gambar di atas, pada kolom Runtime memiliki format yang konsisten berupa angka yang diikuti satuan “min”. Namun, karena masih mengandung

teks, tipe data terbaca sebagai object sehingga perlu dilakukan transformasi menjadi numerik agar dapat digunakan dalam analisis lebih lanjut.

f. Genre

```
df['Genre'].unique()
```

Perintah `df['Genre'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom **Genre** menggunakan library Pandas di Python. Kolom ini berisi informasi mengenai **jenis atau kategori film**, seperti drama, action, comedy, dan lainnya.

```
array(['Drama', 'Crime, Drama', 'Action, Crime, Drama',
       'Action, Adventure, Drama', 'Biography, Drama, History',
       'Action, Adventure, Sci-Fi', 'Drama, Romance', 'Western',
       'Action, Sci-Fi', 'Biography, Crime, Drama',
       'Action, Adventure, Fantasy', 'Comedy, Drama, Thriller',
       'Adventure, Drama, Sci-Fi', 'Animation, Adventure, Family',
       'Drama, War', 'Crime, Drama, Fantasy', 'Comedy, Drama, Romance',
       'Crime, Drama, Mystery', 'Crime, Drama, Thriller',
       'Action, Drama, Mystery', 'Drama, Family, Fantasy', 'Drama, Music',
       'Biography, Comedy, Drama', 'Drama, Mystery, Sci-Fi',
       'Biography, Drama, Music', 'Crime, Mystery, Thriller',
       'Animation, Adventure, Drama', 'Animation, Drama, War',
       'Adventure, Comedy, Sci-Fi', 'Horror, Mystery, Thriller',
       'Drama, Romance, War', 'Comedy, Drama, Family',
       'Animation, Drama, Fantasy', 'Action, Biography, Drama',
       'Animation, Action, Adventure', 'Drama, Western',
       'Action, Adventure', 'Comedy, Drama', 'Drama, Family',
       'Drama, Mystery, Thriller', 'Mystery, Thriller', 'Drama, Horror',
       'Drama, Mystery, War', 'Horror, Sci-Fi', 'Drama, Musical',
       'Comedy', 'Drama, Film-Noir', 'Comedy, Drama, War',
       'Drama, Thriller, War', 'Drama, Fantasy, Horror',
       'Crime, Drama, Music', 'Adventure, Drama, War',
       'Drama, Romance, Sci-Fi', 'Comedy, Romance', 'Comedy, Crime',
       'Drama, Family, Sport', 'Animation, Adventure, Comedy',
       'Adventure, Drama, Thriller', 'Comedy, Crime, Drama',
       'Crime, Drama, Sci-Fi', 'Adventure, Sci-Fi',
       'Adventure, Biography, Drama', 'Adventure, Mystery, Thriller',
       'Mystery, Romance, Thriller', 'Comedy, Musical, Romance',
       'Crime, Drama, Film-Noir', 'Drama, Mystery', 'Drama, Sci-Fi',
       'Action, Drama, War', 'Action, Drama', 'Adventure, Comedy, Drama',
       'Biography, Drama, Sport', 'Action, Comedy, Crime',
       'Action, Biography, Crime', 'Drama, Mystery, Romance',
       'Action, Drama, Sport', 'Drama, Fantasy, War',
       'Action, Drama, Sci-Fi', 'Biography, Drama',
       'Action, Comedy, Romance', 'Animation, Family, Fantasy',
       'Action, Thriller', 'Action, Adventure, Comedy',
       'Adventure, Comedy, Fantasy', 'Adventure, Drama, History',
       'Action, Drama, Thriller', 'Comedy, Music, Romance',
       'Drama, Fantasy, History', 'Crime, Thriller',
       'Adventure, Drama, Western', 'Comedy, War', 'Drama, Thriller']
```

Gambar 10 Genre

Dapat dilihat pada gambar, pada kolom Genre memiliki format penulisan yang konsisten dengan pemisahan menggunakan tanda koma. Namun, setiap baris dapat berisi lebih dari satu genre dalam satu sel.

g. IMDb_Rating

```
df['IMDB_Rating'].unique()
```

Perintah `df['IMDB_Rating'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom **IMDB_Rating** menggunakan library Pandas di Python. Kolom ini berisi nilai rating film yang diberikan oleh pengguna IMDb.

```
df['IMDB_Rating'].unique()

array([9.3, 9.2, 9. , 8.9, 8.8, 8.7, 8.6, 8.5, 8.4, 8.3, 8.2, 8.1, 8. ,
       7.9, 7.8, 7.7, 7.6])
```

Gambar 11 IMDb Rating

Dapat dilihat pada gambar, pada kolom IMDB Rating memiliki tipe data numerik (float) dengan rentang nilai yang konsisten dan tidak ditemukan perbedaan format

maupun nilai yang tidak wajar, sehingga tidak terdapat inconsistent values pada kolom ini.

h. Overview

```
df['Overview'].unique()
```

Perintah `df['Overview'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom Overview menggunakan library Pandas di Python. Kolom ini berisi deskripsi singkat atau ringkasan cerita dari setiap film.

```
array(['Two imprisoned men bond over a number of years, finding solace and eventual redemption through acts of common decency.',
      'An organized crime dynasty's aging patriarch transfers control of his clandestine empire to his reluctant son.',
      'When the menace known as the Joker wreaks havoc and chaos on the people of Gotham, Batman must accept one of the greatest psychological and physical tests of his ability to fight injustice.',
      'The early life and career of Vito Corleone in 1920s New York City is portrayed, while his son, Michael, expands and tightens his grip on the family crime syndicate.',
      'A jury holdout attempts to prevent a miscarriage of justice by forcing his colleagues to reconsider the evidence.',
      'Gandalf and Aragorn lead the World of Man against Sauron's army to draw his gaze from Frodo and Sam as they approach Mount Doom with the One Ring.',
      'The lives of two mob hitmen, a boxer, a gangster and his wife, and a pair of diner bandits intertwine in four tales of violence and redemption.',
      'In German-occupied Poland during World War II, industrialist Oskar Schindler gradually becomes concerned for his Jewish workforce after witnessing their persecution by the Nazis.',
      'A thief who steals corporate secrets through the use of drone-stealing technology is given the inverse task of planting an idea into the mind of a C.E.O.',
      'An insomniac office worker and a devil-may-care soapmaker form an underground fight club that evolves into something much, much more.',
      'A meek Hobbit from the Shire and eight companions set out on a journey to destroy the powerful One Ring and save Middle-earth from the Dark Lord Sauron.',
      'The presidencies of Kennedy and Johnson, the events of Vietnam, Watergate and other historical events unfold through the perspective of an Alabama man with an IQ of 75, whose only desire is to be reunited with his childhood sweetheart.',
      'A bounty hunting scam joins two men in an uneasy alliance against a third in a race to find a fortune in gold buried in a remote cemetery.',
      'While Frodo and Sam edge closer to Mordor with the help of the shifty Gollum, the divided fellowship makes a stand against Sauron's new ally, Saruman, and his hordes of Isengard.',
      'When a beautiful stranger leads computer hacker Neo to a forbidding underworld, he discovers the shocking truth—the life he knows is the elaborate deception of an evil cyber-intelligence.',
      'The story of Henry Hill and his life in the mob, covering his relationship with his wife Karen Hill and his mob partners Jimmy Conway and Tommy DeVito in the Italian-American crime syndicate.',
      'After the Rebels are brutally overpowered by the Empire on the ice planet Hoth, Luke Skywalker begins Jedi training with Yoda, while his friends are pursued by Darth Vader and a bounty hunter named Boba Fett all over the galaxy.',
      'A criminal pleads insanity and is admitted to a mental institution, where he rebels against the oppressive nurse and rallies up the scared patients.',
      'The real life of one of America's foremost founding fathers and first Secretary of the Treasury, Alexander Hamilton. Captured live on Broadway from the Richard Rodgers Theater with the original Broadway cast.',
      'Greed and class discrimination threaten the newly formed symbiotic relationship between the wealthy Park family and the destitute Kims.',
      'Nodumean Rajangan "Hara" sets out to make the common man fly and in the process takes on the world's most capital intensive industry and several enemies who stand in his way.',
      'In the slums of Rio, two kids' paths diverge as one struggles to become a photographer and the other a kingpin.',
      'During her family's move to the suburbs, a sullen 10-year-old girl wanders into a world ruled by gods, witches, and spirits, and where humans are changed into beasts.',
      'Following the Normandy landings, a group of U.S. soldiers go behind enemy lines to retrieve a paratrooper whose brothers have been killed in action.',
      'The lives of guards on Death Row are affected by one of their charges: a black man accused of child murder and rape, yet who has a mysterious gift.',
      'When an open-minded Jewish librarian and his son become victims of the Holocaust, he uses a perfect mixture of will, humor, and imagination to protect his son from the dangers around their camp.',
      'Two detectives, a rookie and a veteran, hunt a serial killer who uses the seven deadly sins as his motives.',
      'A young F.B.I. cadet must receive the help of an incarcerated and manipulative cannibal killer to help catch another serial killer, a madman who skins his victims.',
      'Luke Skywalker joins forces with a Jedi Knight, a cocky pilot, a Wookiee and two droids to save the galaxy from the Empire's world-destroying battle station, while also attempting to rescue Princess Leia from the mysterious Darth Vader.',
      'When a ronin requesting seppuku at a feudal lord's palace is told of the brutal suicide of another ronin who previously visited, he reveals how their pasts are intertwined - and in doing so challenges the clan's integrity.',
      'A poor village under attack by bandits recruits seven unemployed samurai to help them defend themselves.',
      'An angel is sent from heaven to help a desperately frustrated businessman by showing him what life would have been like if he had never existed.',
      'In Gotham City, mentally troubled comedian Arthur Fleck is disregarded and mistreated by society. He then embarks on a downward spiral of revolution and bloody crime. This path brings his face-to-face with his
```

Gambar 12 Overview

Dapat dilihat pada gambar, pada kolom Overview berisi deskripsi atau sinopsis film dalam bentuk teks. Format penulisan konsisten dan tidak ditemukan perbedaan struktur data, sehingga tidak terdapat inconsistent values pada kolom ini.

i. Meta_score

```
df['Meta_score'].unique()
```

Perintah `df['Meta_score'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom Meta_score menggunakan library Pandas di Python. Kolom ini berisi nilai metascore yang merupakan penilaian dari kritikus film.

```
df['Meta_score'].unique()

array([ 80., 100., 84., 90., 96., 94., 74., 66., 92., 82., 87.,
        73., 83., nan, 79., 91., 61., 59., 65., 85., 98., 89.,
        88., 57., 67., 62., 77., 64., 75., 97., 99., 78., 68.,
        81., 95., 76., 69., 55., 70., 58., 86., 71., 63., 93.,
        72., 60., 47., 49., 50., 33., 54., 56., 51., 53., 48.,
        44., 45., 40., 52., 28., 36., 46., 30., 41.])
```

Gambar 13 Meta score

Dapat dilihat pada gambar, Kolom Meta_score merupakan inconsistent values namun terdapat nan atau nilai yang kosong.

j. Director

```
df['Director'].unique()
```

Perintah `df['Director'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom Director menggunakan library Pandas di Python. Kolom ini berisi nama sutradara dari setiap film dalam dataset.

```
-- array(['Frank Darabont', 'Francis Ford Coppola', 'Christopher Nolan',
        'Sidney Lumet', 'Peter Jackson', 'Quentin Tarantino',
        'Steven Spielberg', 'David Fincher', 'Robert Zemeckis',
        'Sergio Leone', 'Lars von Trier', 'Martin Scorsese',
        'Irvin Kershner', 'Hideo Nakata', 'Thomas Kail', 'Bong Joon Ho',
        'Sudha Kongara', 'Fernando Trueba', 'Hayao Miyazaki',
        'Roberto Benigni', 'Jonathan Demme', 'George Lucas',
        'Masaki Kobayashi', 'Akira Kurosawa', 'Frank Capra',
        'Todd Phillips', 'Damien Chazelle', 'Olivier Assayas',
        'Roman Polanski', 'Ridley Scott', 'Tony Kaye', 'Bryan Singer',
        'Luc Besson', 'Roger Allers', 'James Cameron',
        'Giuseppe Tornatore', 'Isao Takahata', 'Alfred Hitchcock',
        'Michael Curtiz', 'Charles Chaplin', 'Madine Labaki', 'Can Ukkay',
        'Gayatri', 'Nakoto Sholeka', 'Nitesh Mehta', 'Bob Persichetti',
        'Anthony Russo', 'Lee Unkrich', 'Rajkumar Hirani', 'Aamir Khan',
        'Andrew Stanton', 'Tizian Zuccato', 'Donna Zuccato',
        'Chon-wook Park', 'Stanley Kubrick', 'Hirokazu Kore-eda',
        'Billy Wilder', 'Sam Mendes', 'Ravi Anil Baveja', 'Srikanth Reddy',
        'Zeethu Joseph', 'Thomas Vinterberg', 'Angharad Rees',
        'Denis Villeneuve', 'Mahesh Ali Ojha', 'Cagan Yavuz',
        'Michel Gondry', 'Jean-Pierre Jeunet', 'Guy Ritchie',
        'Darren Aronofsky', 'Sus Van Sant', 'Najid Najid',
        'John Lasseter', 'Mel Gibson', 'Jim Jarmusch', 'Brian De Palma',
        'Richard Linklater', 'Wolfgang Petersen', 'George Roy Hill',
        'David Lean', 'Stanley Donen', 'Vittorio De Sica', 'Orson Welles',
        'Fritz Lang', 'Aditya Dhar', 'Prashanth Neel', 'Peter Farrelly',
        'Martin McDonagh', 'Megha Gulzar', 'S.S. Rajamouli',
        'Sergio Pablos', 'Mahesh Kumar', 'Vikas Saxi', 'Zoya Unshadze',
        'Rakesh Ojha', 'Anurag Kashyap',
        'Vikramaditya Motwane', 'Tigmenshu Dhauli', 'Juan José Campanella',
        'David O'Connor', 'Pete Docter', 'Shinji Aoki',
        'Paul Thomas Anderson', 'Guillermo del Toro', 'James McTeigue',
        'Sanjay Leela Bhansali', 'Ashutosh Gowariker',
        'Oliver Hirschbiegel', 'Ron Howard', 'Priyadarshan',
        'Curtis Hanson', 'Faraz Fajri', 'Michael Mann',
```

Gambar 14 Director

Dapat dilihat pada gambar, pada kolom Director berisi nama sutradara dalam format teks dengan struktur penulisan yang konsisten. Tidak ditemukan perbedaan format maupun nilai yang tidak sesuai, sehingga tidak terdapat inconsistent values pada kolom ini.

k. Star 1

```
df['Star1'].unique()
```

Perintah `df['Star1'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom Star1 menggunakan library Pandas di Python. Kolom ini berisi nama aktor atau aktris utama yang berperan dalam film.

```
-- array(['Tim Robbins', 'Marlon Brando', 'Christian Bale', 'Al Pacino',
        'Henry Fonda', 'Elijah Wood', 'John Travolta', 'Liam Neeson',
        'Leonardo DiCaprio', 'Brad Pitt', 'Tom Hanks', 'Clint Eastwood',
        'Lilly Wachowski', 'Robert De Niro', 'Mark Hamill',
        'Jack Nicholson', 'Lin-Manuel Miranda', 'Kang-ho Song', 'Suriya',
        'Matthew McConaughey', 'Katie Lund', 'Daveigh Chase',
        'Roberto Benigni', 'Hogan Freeman', 'Jodie Foster',
        'Tatsuya Nakadai', 'Toshirō Mifune', 'James Stewart',
        'Joaquin Phoenix', 'Miles Teller', 'Eric Toledano', 'Adrien Brody',
        'Russell Crowe', 'Edward Norton', 'Kevin Spacey', 'Jean Reno',
        'Bob Odenkirk', 'Arnold Schwarzenegger', 'Philippe Noiret',
        'Tsumugu Tatsumi', 'Michael J. Fox', 'Anthony Perkins',
        'Munichy Robert', 'Charles Chaplin', 'Zain Al Rafeea',
        'Freddy Lee', 'Pushkar', 'Byronne Kanika', 'Aamir Khan',
        'Peter Ramsey', 'Joe Russo', 'Adrian Poline', 'Amla Fox',
        'Anita Datta', 'Ben Hurtt', 'Ulrich Mue', 'Choi Min-sik',
        'Guy Pearce', 'Vijay Vasudeva', 'Marrison Ford', 'Muntin Shreen',
        'Sigourney Weaver', 'Rajesh Khanna', 'Peter Sellers',
        'Lynne Foweraker', 'Kirk Douglas', 'William Holden',
        'Dean-Carl Chapman', 'Anand Gandhi', 'Ayushman Khurrana',
        'Nehal', 'Kado Hikkelsen', 'Paymen Haddi', 'Lubna Azabal',
        'Anas Bulut Tynemil', 'Cetin Tekindor', 'Jim Carrey',
        'Audrey Tautou', 'Jason Statham', 'Ellen Barkin',
        'Robin Williams', 'Mohammad Amir Naji', 'Mel Gibson',
        'Harvey Keitel', 'Matthew Modine', 'Alekssey Kravchenko',
        'F. Murray Abraham', 'Jurgen Prochnow', 'Paul Newman',
        'Malcolm McDowell', 'Walter Dillie', 'Peter O'Toole', 'Jack Lemmon',
        'Cary Grant', 'Gene Kelly', 'Takashi Shimura',
        'Lamberto Paggiaroni', 'Fred MacMurray', 'Orson Welles',
        'Peter Leone', 'Brigitte Nola', 'Sukant Singh Rajput',
        'Vicky Kaushal', 'Vash', 'Viggo Mortensen', 'Frances McDormand',
        'Irfan Khan', 'Prashant', 'Carlos Martínez López', 'Ajay Devgn',
        'Kangana Ranaut', 'Lembit Ulfak', 'Farhan Akhtar',
        'Manoj Bajpayee', 'Rajat Bermecha', 'Ricardo Darin', 'Tom Hardy',
        'Bob Peterson', 'Shah Rukh Khan', 'Daniel Day-Lewis',
```

Gambar 15 Star 1

Dapat dilihat pada gambar, pada kolom Star 1 berisi nama pemeran utama dalam format teks yang konsisten. Tidak ditemukan perbedaan struktur penulisan maupun nilai yang tidak sesuai, sehingga tidak terdapat inconsistent values pada kolom ini.

l. Star 2

```
df['Star2'].unique()
```

Perintah `df['Star2'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom Star2 menggunakan library Pandas di Python. Kolom ini berisi nama aktor atau aktris utama yang berperan dalam film.

```
== array(['Norgan Freeman', 'Al Pacino', 'Heath Ledger', 'Robert De Niro',
        'Lee J. Cobb', 'Wiggo Mortensen', 'Uma Thurman', 'Ralph Fiennes',
        'Joseph Gordon-Levitt', 'Edward Norton', 'Ian McKellen',
        'Robin Wright', 'Ellie Simmonds', 'Keanu Reeves', 'Ray Liotta',
        'Harrison Ford', 'Louise Plotch', 'Phillipo Soo', 'Lee Sun-kyun',
        'Madhavan', 'Anna Hathaway', 'Alexandra Rodriguez',
        'Suzanne Plashette', 'Matt Damon', 'Michael Clarke Duncan',
        'Nicolette Braschi', 'Brad Pitt', 'Anthony Hopkins',
        'Akira Ishihara', 'Takashi Shimura', 'Donna Reed', 'J.K. Simmons',
        'Francis Cluzet', 'Hugh Jackman', 'Thomas Bretschmann',
        'Joaquin Phoenix', 'Edward Furlong', 'Gabriel Byrne',
        'Gary Oldman', 'Matthew Broderick', 'Linda Hamilton',
        'Enzo Cannavale', 'Byron Shiroishi', 'Christopher Lloyd',
        'Charles Bronson', 'Janet Leigh', 'Erin O'Brien',
        'Pauline Daddard', 'Virginia Cherrill', 'Yordanos Shiferaw',
        'Cetin Tekindor', 'Mona Kamishiraishi', 'Sakshi Tanwar',
        'Rodney Anthony', 'Robert Downey Jr.', 'Anthony Gonzalez',
        'Christoph Waltz', 'Tom Hardy', 'Damian Lewis', 'Silvia Knight',
        'Martina Gedeck', 'Voo Ji-Tae', 'Camille-Anne Ross',
        'Yuriko Ishida', 'James Woods', 'Karen Allen', 'Shelley Long',
        'Marlon Brando', 'Tom Skerritt', 'Amelia Backham', 'Mitsuki Sade',
        'George C. Scott', 'Marlene Dietrich', 'Ralph Houck',
        'Grace Kelly', 'Gloria Swanson', 'George Mackay', 'Adesh Prasad',
        'Tate', 'Heena', 'Thomas Ro Larsen', 'Lilla Hatami',
        'Melissa O'Sullivan', 'Nisa Sofiya Aksongur',
        'Fikret Kuskan', 'Diana Kruger', 'Kate Winslet',
        'Mathieu Kassovitz', 'James Leto', 'Annette Bening',
        'Amir Farrokh Hashemian', 'Tim Allen', 'Sophie Marceau',
        'Tim Roth', 'R. Lee Ermey', 'Viggo Mortensen', 'Michael Biehn',
        'Tom Hanks', 'Michelle Pfeiffer', 'Herbert Grönemeyer',
        'Zoe Foster', 'Robert Redford', 'Patrick Magee', 'Gary Lockwood',
        'Lee Van Cleef', 'Alec Guinness', 'Shirley MacLaine',
        'Frodo Baggins', 'Kia Krawak', 'Gene Kelly', 'Hideo Kanezo',
        'Enzo Staiola', 'Barbara Stanwyck', 'Joseph Cotten',
        'Ellen Widmann', 'Alfred Abel', 'Edna Purviance',
        'Shradha Kapoor', 'Parvati Kaul', 'Srinidhi Shetty',
        'Nandishia Ali', 'Randy Harrison', 'Tomoko Santhana',
        'Rana Daggubati', 'Jason Schwartzman', 'Shriya Saran',
```

Gambar 16 Star 2

Dapat dilihat pada gambar, pada kolom Star 2 berisi nama pemeran pendukung dalam format teks yang konsisten. Tidak ditemukan perbedaan struktur penulisan maupun nilai yang tidak sesuai, sehingga tidak terdapat inconsistent values pada kolom ini.

m. Star 3

```
df['Star3'].unique()
```

Perintah `df['Star3'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom Star3 menggunakan library Pandas di Python. Kolom ini berisi nama aktor atau aktris utama yang berperan dalam film.

```

== array(['Bob Gunton', 'James Caan', 'Baron Eckhart', 'Robert Duvall',
'Martin Balsam', 'Ian McEwan', 'Samuel L. Jackson',
'Ben Kingsley', 'Elliot Page', 'West Leaff', 'Orlando Bloom',
'Gary Sinise', 'Lee Van Cleef', 'Viggo Mortensen',
'Laurence Fishburne', 'Joe Pesci', 'Carrie Fisher',
'Michael Berryman', 'Leslie Odom Jr.', 'Cho Yeo-jeong',
'Pavani Ramli', 'Jessica Chastain', 'Leandro Firmino',
'Miya Irino', 'Tom Sizemore', 'David Morse', 'Giorgia Cantarini',
'Kevin Spacey', 'Laurence A. Bonney', 'Shina Washita',
'Kelko Tushitso', 'Lionel Barrymore', 'Zaria Rost',
'Melissa Rowlett', 'Omar Ly', 'Scarlett Johansson',
'Jack Nicholson', 'Frank Finlay', 'Connie Nielsen',
'Beverly D'Angelo', 'Chaz Palminteri', 'Natalie Portman',
'Jeremy Irons', 'Edward Furlong', 'Antonella Attili',
'Abon Yewaguchi', 'Tom Thompson', 'Claudia Cardinale',
'Vera Miles', 'Paul Henreid', 'Henry Bergman', 'Florence Lee',
'Belouafite Treasure Benkole', 'Isaell Hecloglu',
'Vijay Varughese', 'Bye Baris', 'Patina Sana Shalkh',
'Shaadik Moore', 'Chris Evans', 'Chris Hemsworth',
'Gael Garcia Bernal', 'Leonardo DiCaprio', 'Anne Hathaway',
'Mona Singh', 'Aamir Khan', 'Jeff Garlin', 'Sebastian Koch',
'Kang Hye-jeong', 'Joe Pantoliano', 'Yoko Tawaka',
'Ellen Barkin', 'Paul Freeman', 'Dany Lilay', 'John Hurt',
'Sumra Sayal', 'Tatsuya Nakadai', 'Starling Hayden',
'Charles Laughton', 'Adolphe Menjou', 'Wendell Corey',
'Erich von Stroheim', 'Jack O'Keefe', 'Daniel Hays', 'Sohun Shah',
'Naohiko Apte', 'Asa Sornath', 'Anika Wodderkop', 'Soren Bayat',
'Naxin Gaudette', 'Denzil Walsal', 'Hameyra', 'Ell Roth',
'Tom Wilkinson', 'Rufus', 'Benicio Del Toro', 'Jennifer Connelly',
'Thara Birch', 'Ben Affleck', 'Bahare Seddiqi', 'Don Rickles',
'Patrick McGoohan', 'Michael Madson', 'Vincent D'Ovizio',
'Libonirax Iacovicius', 'Carrie Huan', 'Elizabeth Beridge',
'Steven Bauer', 'Klaus Monnemann', 'Cybill Shepherd',
'Robert Shaw', 'Michael Bates', 'William Sylvester',
'Gian Maria Volante', 'Anthony Quinn', 'Fred MacMurray',
'James Mason', 'Barbara Del Goddes', 'Donald O'Connor',
'Shin-ichi Himori', 'Lianella Carell', 'Edward G. Robinson',
'Dorothy Conington', 'Inge Landgut', 'Gunter Fröhlich',
'Jackie Conger', 'Vera Sharma', 'Holt Raine', 'Rameshendra Raja',
'Linda Cardellini', 'Sam Rockwell', 'Nawaz Kabi',

```

Gambar 17 Star 3

Dapat dilihat pada gambar, pada kolom Star 3 berisi nama pemeran pendukung dalam format teks yang konsisten. Tidak ditemukan perbedaan struktur penulisan maupun nilai yang tidak sesuai, sehingga tidak terdapat inconsistent values pada kolom ini.

n. Star 4

```
df['Star4'].unique()
```

Perintah `df['Star4'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom Star4 menggunakan library Pandas di Python. Kolom ini berisi nama aktor atau aktris utama yang berperan dalam film.

```

== array(['William Sadler', 'Blaise Keston', 'Michael Caine', 'John Fiedler',
'Orlando Bloom', 'Bruce Willis', 'Caroline Goodall',
'Ken Watanabe', 'Zach Brafford', 'Sam Bean', 'Sally Field',
'Aldo Giuffrè', 'Carrie-Anne Moss', 'Lorraine Bracco',
'Kelly Rowland', 'Peter Onorati', 'Kanda Ellis Goldberry',
'Choi Woo-sik', 'Apurva Kalamruti', 'Mackenzie Foy',
'Matthias Nachtergaele', 'Rumi Hiliragi', 'Edward Burns',
'Romeo Hunt', 'Giustino Durano', 'Andrew Kevin Walker',
'Kasi Lemons', 'Alec Guinness', 'Tetsuro Tanba',
'Vukto Staszczak', 'Thomas Huchall', 'Frances Conroy',
'Paul Reiser', 'Anne Le Ny', 'Mark Wahlberg', 'Emilia Fox',
'Oliver Reed', 'Jennifer Lien', 'Stephen Baldwin', 'Danny Aiello',
'James Earl Jones', 'Robert Patrick', 'Isa Daniel',
'Yoshino Shimura', 'Crispin Glover', 'Jason Roberts',
'John Gavin', 'Claude Rains', 'Tina Turner', 'Harry Myers',
'Kawar Al Haddad', 'Kyoung-in Lee', 'Shradha Srinath',
'Isa Yaki', 'Sonya Balchova', 'Jake Johnson', 'Mark Ruffalo',
'Benjamin Bratt', 'Kerry Washington', 'Gary Oldman',
'Sharman Joshi', 'Tisca Chopra', 'Fred Willard', 'Ulrich Tukur',
'Kim Byung-ok', 'Mark Boone Junior', 'Billy Crudup',
'Treat Williams', 'John Rys Davies', 'Steven Crothers',
'Frederic Forrest', 'Veronica Cartwright', 'Ramesh Doo',
'Kyoko Kagawa', 'Keenen Ivory', 'Eise Lencheater',
'George Macready', 'Thelma Ritter', 'Nancy Olson',
'Regina Lardner', 'Collin Hirth', 'Spud Winkle', 'Anil Dhaman',
'Antibo', 'Lasse Fogelstrom', 'Shahab Hosseini', 'Mustafa Kamel',
'Cellie Toyn Oyal', 'Ege Tennen', 'Melanie Laurent',
'Garry Robert Byrne', 'Lorella Cravotta', 'Dennis Farina',
'Marlon Hovany', 'Wes Bentley', 'Stellan Skarsgård',
'Hafsa Tafar-Mohammed', 'Jim Varney', 'Angus Macfadyen',
'Chris Penn', 'Adam Baldwin', 'Vidas Bagdonas', 'Roy Dotrice',
'Mary Elizabeth Mastrantonio', 'Homerus Bengis', 'Elbert Brucke',
'Charles Durning', 'Warren Clarke', 'Daniel Richter', 'Mara Crisp',
'Jack Hawkins', 'Ray Walston', 'Jessie Royce Landis',
'Tom Helmore', 'Debbie Reynolds', 'Haruo Tanaka', 'Elena Altieri',
'Byron Barr', 'Igwe Moorehead', 'Otis Harlick',
'Rudolf Klein-Rogge', 'Carl Miller', 'Prateek', 'Vani Gautam',
'Archana Jais', 'Sebastian Montalco', 'Caleb Landry Jones',
'Somun Shah', 'Tasneem Bhutta', 'Rashida Jones', 'Rajet Kapoor',

```

Gambar 18 Star 4

Dapat dilihat pada gambar, pada kolom Star 4 berisi nama pemeran pendukung dalam format teks yang konsisten. Tidak ditemukan perbedaan struktur penulisan maupun nilai yang tidak sesuai, sehingga tidak terdapat inconsistent values pada kolom ini.

o. No_of_Votes

```
df['No_of_Votes'].unique()
```

Perintah `df['No_of_Votes'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom `No_of_Votes` menggunakan library Pandas di Python. Kolom ini berisi jumlah voting yang diberikan oleh pengguna IMDb terhadap setiap film.

```
array([2841110, 1628807, 2385332, 1129952, 688045, 1042758, 1820188,
       1215585, 2867042, 1854708, 1561681, 1880221, 688369, 1485555,
       1676126, 1836727, 1158155, 928888, 85291, 852778, 84999,
       2512388, 699258, 651376, 1231889, 1347794, 621829, 1048900,
       1278197, 1214773, 42004, 251744, 408891, 939252, 717585,
       788388, 1198255, 1189773, 729883, 1341468, 1034705, 991288,
       1875236, 843845, 895266, 274763, 232231, 1058881, 588644,
       684211, 522893, 217801, 167839, 62635, 34112, 28481,
       184838, 156679, 375138, 889655, 834677, 384171, 1357682,
       1516368, 144605, 188805, 889788, 358689, 51585, 1135712,
       831371, 111995, 886112, 886232, 888198, 787889, 38275,
       34357, 458474, 188882, 178892, 444074, 201932, 282259,
       425884, 27793, 71875, 38722, 281623, 228882, 158823,
       23925, 78825, 125785, 911684, 788118, 788888, 78878,
       1889738, 851688, 85341, 887429, 558181, 918561, 675145,
       58856, 652719, 358887, 748811, 856478, 251855, 724838,
       241513, 757884, 685517, 232772, 288885, 104381, 289388,
       884888, 218857, 88485, 148227, 148229, 483151, 148418,
       159892, 115114, 39889, 48448, 38888, 377884, 82818,
       31142, 75248, 184782, 78267, 68781, 88382, 61137,
       82365, 42241, 33227, 193217, 432958, 1129884, 932597,
       1187488, 74125, 517359, 818823, 757812, 382748, 118137,
       31354, 138888, 83885, 313888, 338515, 848888, 83887,
       53216, 531887, 84118, 577113, 468278, 49888, 37835,
       882368, 26482, 281188, 781184, 112585, 321888, 118845,
       26875, 43888, 51288, 888875, 228788, 288111, 111244,
       48848, 248848, 98881, 184218, 28818, 138135, 53155,
       152572, 128539, 114884, 29915, 388882, 41888, 83134,
       39228, 47788, 141536, 113648, 50788, 58485, 647884,
       371538, 177855, 159171, 46547, 163881, 51778, 78838,
       85885, 38888, 435788, 65228, 75771, 68877, 43811,
       281288, 42815, 51678, 57888, 67877, 681148, 882718,
       71881, 728858, 784881, 48582, 253575, 164882, 686778,
       572821, 898158, 42157, 69078, 33828, 37828, 23811,
       71892, 138538, 88881, 188818, 94888, 82388, 22748,
       81588, 38847, 18888, 21573, 50888, 92881, 58882,
       73288, 124381, 63478, 65444, 51228, 158345, 63515,
       272291, 88729, 81122, 88715, 15842, 25888, 29682,
       425457, 36388, 38122, 91188, 158528, 37127, 78881,
```

Gambar 19 No of Votes

Dapat dilihat pada gambar, pada kolom `No of Votes` berisi jumlah suara penonton dalam bentuk angka yang konsisten. Tidak ditemukan nilai yang tidak sesuai maupun format yang berbeda.

p. Gross

```
df['Gross'].unique()
```

Perintah `df['Gross'].unique()` digunakan untuk menampilkan semua nilai unik yang terdapat pada kolom `Gross` menggunakan library Pandas di Python. Kolom ini berisi informasi mengenai pendapatan kotor yang diperoleh film dari penayangannya.

```
array(['28,341,408', '134,866,411', '534,858,444', '57,388,888',
       '4,568,888', '377,845,885', '187,528,762', '80,888,818',
       '282,576,195', '37,878,182', '215,544,758', '358,252,182',
       '6,188,888', '142,551,387', '171,479,938', '45,835,784',
       '290,475,887', '112,888,888', '21,367,844', '188,828,812',
       '7,563,387', '10,855,850', '216,548,909', '135,881,374',
       '57,588,287', '108,125,843', '138,742,922', '322,748,148',
       '258,881', '251,851,211', '11,888,888', '13,181,881', '58,888,888',
       '132,884,315', '82,572,577', '187,788,427', '9,718,888',
       '28,141,188', '10,581,238', '422,783,777', '298,881,858',
       '11,888,888', '118,888,787', '5,821,888', '12,888,888',
       '1,824,588', '188,248', '10,181', '1,888,888', '5,817,248',
       '12,181,781', '188,281,818', '888,178,888', '678,815,887',
       '188,788,815', '182,188,534', '448,178,888', '6,532,888',
       '1,221,888', '228,888,184', '11,388,312', '787,481', '25,544,887',
       '1,575,388', '248,158,921', '44,817,374', '83,471,511',
       '78,888,888', '775,381', '8,175,888', '36,784,511', '288,475',
       '118,227,884', '1,371,841', '687,181', '1,888,888', '6,887,888',
       '128,548,719', '34,488,381', '33,225,489', '18,328,156',
       '3,635,482', '138,888,888', '128,433,435', '932,932',
       '181,788,233', '75,888,888', '2,812,888', '48,357,878',
       '85,168,248', '51,977,828', '45,588,887', '388,125,488',
       '11,487,678', '28,252,574', '158,888,888', '6,287,725',
       '55,554,952', '15,888,888', '44,324,444', '18,888,888',
       '15,257,888', '1,288,888', '8,819,828', '55,248', '332,388',
       '5,728,888', '1,585,434', '28,877', '1,228,188', '5,488,888',
       '888,175', '4,188,188', '85,888,171', '54,511,748', '242,778',
       '28,188,888', '758,478', '1,428,554', '184,281', '1,828,289',
       '7,481', '38,587', '8,821,428', '11,857,115', '128,812,984',
       '289,888,184', '118,888,888', '1,118,541', '48,222,514',
       '47,438,155', '418,888,888', '78,118,888', '2,187,311', '238,888',
       '288,812,312', '1,221,288', '8,888,888', '4,211,888',
       '178,742,341', '3,887,588', '86,616,948', '67,438,818',
       '42,438,188', '181,125,843', '187,171,888', '288,815', '1,188,984',
       '81,888,812', '4,135,788', '33,181,887', '254,713', '1,228,187',
       '12,188,888', '25,888,888', '57,228', '12,581', '86,588', '18,177',
       '5,014,888', '977,375', '3,759,854', '1,241,225', '2,088,788',
       '1,491,714', '888,818', '126,377,888', '14,277,874', '3,187,472',
       '188,128', '10,816,184', '923,221', '58,188,218', '187,787,188',
       '67,288,815', '758,481,711', '2,884,674', '56,671,993',
       '28,947,628', '117,628,828', '45,855,778', '857,324', '1,036,932',
```

Gambar 20 Gross


Dapat dilihat pada gambar, pada kolom Gross berisikan pendapatan kotor film, namun masih bertipe data object karena terdapat tanda koma (,) sebagai pemisah ribuan.

3. Missing Values

Missing Values merupakan kondisi ketika terdapat data yang kosong atau tidak terisi pada suatu kolom dalam dataset. Hal ini dapat terjadi karena data tidak tersedia, kesalahan saat pengumpulan data, atau proses input yang tidak lengkap. Oleh karena itu, perlu dilakukan pengecekan terhadap missing values agar kualitas data tetap terjaga sebelum dilakukan analisis lebih lanjut.

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])
```

Perintah ini digunakan untuk menghitung persentase data kosong pada setiap kolom dalam dataset menggunakan Pandas di Python. Output ditampilkan dalam bentuk DataFrame sehingga memudahkan melihat kolom yang memiliki nilai kosong.



	Null Ratio in %
Poster_Link	0.0
Series_Title	0.0
Released_Year	0.0
Certificate	10.1
Runtime	0.0
Genre	0.0
IMDB_Rating	0.0
Overview	0.0
Meta_score	15.7
Director	0.0
Star1	0.0
Star2	0.0
Star3	0.0
Star4	0.0
No_of_Votes	0.0
Gross	16.9

Gambar 21 Missing Values

Dapat dilihat pada gambar, Certificate memiliki missing values sekitar 10.1% yang dimana jumlah ini masih tergolong rendah. Nilai kosong pada kolom ini kemungkinan

disebabkan karena tidak semua film memiliki klasifikasi usia yang tercantum. Kolom ini dapat ditangani atau dihapus.


Meta_score Memiliki missing values sekitar 15.7%, yang dimana persentase ini cukup signifikan dibanding kolom lainnya. Hal ini kemungkinan terjadi karena tidak semua film memiliki penilaian dari kritikus. Kolom Gross juga memiliki presentase yang cukup signifikan yakni 16.9%. Oleh karena itu, kolom ini perlu ditangani atau dihapus.

4. Duplicated Values

Duplicated values adalah data yang muncul lebih dari satu kali dalam dataset dengan nilai yang sama pada baris yang sama. Duplikasi ini biasanya terjadi karena kesalahan saat pengumpulan atau penyimpanan data.

```
df[df.duplicated()]
```

Perintah ini digunakan untuk menampilkan baris data yang duplikat dalam dataset menggunakan Pandas di Python. Hal ini dilakukan untuk mengetahui apakah terdapat data yang sama lebih dari satu kali dalam dataset.



Gambar 22 Duplicated Values

Dapat dilihat pada gambar, dataset tidak memiliki duplicated values, sehingga tidak diperlukan proses penghapusan data duplikat.

5. Outliers

Outlier adalah nilai data yang sangat berbeda atau jauh dari sebagian besar data lainnya dalam suatu dataset. Nilai ini bisa berupa nilai yang terlalu tinggi atau terlalu rendah dibandingkan pola umum data.

```
results = []

cols = df.select_dtypes(include=['float64', 'int64'])

for col in cols:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
```

```


lower_bound = q1 - 1.5*iqr
upper_bound = q3 + 1.5*iqr
outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
percent_outliers = (len(outliers)/len(df))*100
results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

# Dataframe dari list hasil
results_df = pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
results_df = results_df.rename_axis(None, axis=0).rename_axis('Kolom', axis=1)

# Tampilkan dataframe
display(results_df)

```


Perintah ini digunakan untuk mendeteksi persentase outliers pada setiap kolom numerik dalam dataset menggunakan metode IQR dengan bantuan Pandas di Python. Program menghitung batas bawah dan batas atas data, lalu menentukan berapa persen data yang termasuk outliers pada setiap kolom.



Kolom	Persentase Outliers
IMDB_Rating	1.3
Meta_score	0.7
No_of_Votes	6.7


Gambar 23 Outliers

Pada kolom No_of_Votes terdapat outliers dengan presentase sebesar 6.7%, merupakan kolom dengan jumlah outliers tertinggi. Kemudian, pada kolom IMDB_Rating memiliki outliers dengan presentase sebesar 1.3% dan Meta_score dengan presentase paling rendah yaitu 0.7% (di bawah 1%).




Gambar 24 Boxplot No of Votes

Boxplot pada kolom No_of_Votes memiliki persentase outliers sebesar 6.7%, yang merupakan yang tertinggi dibandingkan kolom lainnya.



Gambar 25 Boxplot IMDb Rating

Boxplot pada IMDB_Rating menunjukkan adanya film dengan rating yang jauh lebih tinggi dibandingkan mayoritas film lainnya.



Gambar 26 Boxplot Meta Score

Boxplot pada Meta_score menunjukkan adanya titik-titik yang berarti terdapat film dengan meta score jauh lebih rendah dibandingkan mayoritas film lainnya.

2.2.5 Eksplorasi Data (EDA)

Exploratory Data Analysis (EDA) merupakan proses awal dalam analisis data yang bertujuan untuk memahami karakteristik data melalui ringkasan statistik dan visualisasi. Tahap ini membantu mengidentifikasi pola, hubungan antar variabel, serta menemukan kemungkinan adanya kesalahan atau kejanggalan pada data sebelum dilakukan analisis lebih lanjut.

1. Comparison/Perbandingan

Comparison dalam analisis IMDb Movies Dataset digunakan untuk membandingkan nilai antar kategori agar terlihat mana yang lebih unggul.

```


rating_genre =
df.groupby('Genre')['IMDB_Rating'].mean().sort_values(ascending=False)

top10_genre = rating_genre.head(10)

plt.figure(figsize=(10,6))
sns.barplot(y=top10_genre.index, x=top10_genre.values, palette='viridis')
plt.title('Top 10 Genre dengan Rata-rata IMDB Rating Tertinggi')
plt.xlabel('Rata-rata IMDB Rating')
plt.ylabel('Genre')
plt.show()

```

Perintah ini digunakan untuk mengelompokkan data film berdasarkan genre, menghitung rata-rata rating IMDB pada setiap genre, kemudian memilih 10 genre dengan rata-rata rating tertinggi dan menampilkannya dalam bentuk grafik batang agar perbandingan rating antar genre dapat terlihat dengan lebih jelas.



Gambar 27 Comparison

Pada grafik Top 10 Genre dengan Rata-rata IMDb Rating Tertinggi, terlihat bahwa genre Animation, Drama, War memiliki rata-rata rating lebih tinggi dibanding genre lain seperti Adventure, Mystery, Thriller. Hal ini menunjukkan bahwa setiap genre memiliki kualitas yang berbeda menurut penilaian penonton. Analisis perbandingan seperti ini

penting karena membantu mengidentifikasi kategori yang menonjol, baik dari sisi rating maupun votes. Dengan begitu, kita bisa mengetahui genre atau aktor mana yang lebih konsisten menghasilkan film berkualitas tinggi, sehingga dapat dijadikan acuan dalam pengambilan keputusan.

2. Composition/Komposisi


Composition pada analisis IMDb Movies Dataset digunakan untuk melihat proporsi atau kontribusi suatu kategori terhadap keseluruhan data

```
votes_actor = df.groupby('Star1')['No_of_Votes'].sum().sort_values(ascending=False)

top5_actor = votes_actor.head(3)

plt.figure(figsize=(10,8))
top5_actor.plot(kind='pie', autopct='%1.1f%%', startangle=140,
colors=plt.cm.Paired.colors)
plt.title('Top 3 Aktor Utama Berdasarkan Total Votes')
plt.ylabel("")
plt.axis('equal')
plt.show()
```

Perintah ini digunakan untuk mengelompokkan data berdasarkan aktor utama (*Star1*), kemudian menghitung total jumlah suara (*No_of_Votes*) yang diperoleh setiap aktor. Selanjutnya dipilih 3 aktor dengan total vote tertinggi, lalu hasilnya ditampilkan dalam diagram pie untuk memperlihatkan perbandingan persentase jumlah vote masing-masing aktor.



Gambar 28 Composition

Melalui pie chart Top 3 Aktor Utama (Star1) Berdasarkan Total Votes (No_of_Votes), terlihat bahwa Leonardo DiCaprio menyumbang 37% dari total suara penonton, Tom Hanks 32.2%, dan Christian Bale 30.7%. Hal ini menunjukkan bahwa ketiga aktor tersebut memiliki daya tarik besar dalam menarik penonton untuk memberikan rating. Analisis komposisi seperti ini membantu industri perfilman memahami aktor atau genre mana yang paling dominan dalam memengaruhi popularitas film, sehingga dapat dijadikan pertimbangan dalam pemilihan pemain maupun strategi produksi.

3. Distribution/Distribusi


Distribution dalam analisis IMDb Movies Dataset digunakan untuk melihat bagaimana data tersebar pada suatu variabel.

```
plt.figure(figsize=(10,6))
sns.histplot(df['IMDB_Rating'], bins=20, kde=True, color='skyblue')
plt.title('Distribusi IMDb Rating')
```



```
plt.xlabel('IMDb Rating')
plt.ylabel('Frekuensi')
plt.show()
```

Perintah ini digunakan untuk memvisualisasikan distribusi nilai IMDb_Rating pada dataset menggunakan histogram. Grafik ini menampilkan sebaran rating film, dengan jumlah data pada setiap rentang rating ditunjukkan melalui batang histogram, serta ditambahkan garis KDE (Kernel Density Estimation) untuk memperlihatkan pola distribusi data secara lebih halus.




Gambar 29 Distribution

Pada grafik Distribusi IMDb Rating, terlihat bahwa mayoritas film memiliki rating yang terkonsentrasi di kisaran 7.5–8.0. Hal ini menunjukkan bahwa sebagian besar film dalam dataset dinilai cukup tinggi oleh penonton, sementara hanya sedikit film yang memiliki rating sangat rendah atau sangat tinggi. Analisis distribusi seperti ini penting karena membantu memahami pola umum dalam data. Dengan melihat sebaran rating, kita bisa mengetahui standar kualitas film menurut penonton, apakah cenderung tinggi, sedang, atau rendah. Distribusi juga dapat digunakan untuk mendeteksi adanya outlier, yaitu film dengan rating yang jauh berbeda dari mayoritas.

4. Relation/Hubungan

Relationship dalam analisis IMDb Movies Dataset digunakan untuk melihat hubungan antar variabel, apakah satu variabel memengaruhi atau berkaitan dengan variabel lain.

```
plt.figure(figsize=(8, 6))
sns.heatmap(
    data=df[['No_of_Votes', 'IMDB_Rating']].corr(),
    annot=True,
    cmap='viridis',
    fmt='.2f'
)
plt.title('Korelasi antara Jumlah Votes dan IMDb Rating')
plt.show()
```



Gambar 30 Relation

Pada heatmap Korelasi antara Jumlah Votes dan IMDb Rating, terlihat nilai korelasi sebesar 0.49. Angka ini menunjukkan adanya hubungan positif sedang antara jumlah votes dengan rating, semakin banyak penonton yang memberikan suara, cenderung rating film juga lebih tinggi, meskipun tidak selalu kuat. Analisis relationship seperti ini penting karena membantu memahami keterkaitan antara popularitas dan kualitas. Dengan mengetahui adanya korelasi, industri perfilman bisa menilai bahwa film yang populer (banyak votes) umumnya juga dianggap berkualitas oleh penonton. Namun, karena korelasinya tidak terlalu tinggi, hal ini juga menegaskan bahwa popularitas tidak selalu identik dengan kualitas

2.3 Data Preparation

Pada tahap ini dilakukan proses data preparation atau persiapan data sebelum data dianalisis lebih lanjut. Tahap ini bertujuan untuk memastikan bahwa data yang digunakan memiliki kualitas yang baik, konsisten, dan siap untuk proses analisis. Proses ini meliputi beberapa langkah seperti menangani data yang tidak konsisten (Inconsistent Values), mengatasi nilai kosong (Missing Values), menghapus data duplikat (Duplicated Values), mendeteksi dan menangani outlier, serta melakukan transformasi data seperti pembuatan kolom (Data Construction) baru atau penghapusan kolom yang tidak diperlukan (Data Reduction). Setiap permasalahan pada data ditangani menggunakan metode yang sesuai agar dataset menjadi lebih bersih dan representatif untuk analisis selanjutnya.

2.3.1 Data Type

Tipe data (data type) adalah klasifikasi atau atribut yang menentukan jenis nilai yang dapat ditampung oleh suatu variabel dan bagaimana data tersebut diproses, disimpan, atau dimanipulasi oleh program komputer. Perintah di bawah ini digunakan untuk mengecek tipe data dari setiap kolom yang ada di dalam DataFrame.

```
df.dtypes
```

Perintah `df.dtypes` ini digunakan untuk menampilkan tipe data dari setiap kolom yang terdapat pada dataset.

...	0
Poster_Link	object
Series_Title	object
Released_Year	object
Certificate	object
Runtime	object
Genre	object
IMDB_Rating	float64
Overview	object
Meta_score	float64
Director	object
Star1	object
Star2	object
Star3	object
Star4	object
No_of_Votes	int64
Gross	object
dtype: object	

Gambar 31 Data Type

Dari output tersebut dapat diketahui apakah suatu kolom bertipe object (teks/kategori), float (bilangan desimal), atau int (bilangan bulat). Informasi ini penting dalam tahap *data preparation* karena membantu menentukan proses pembersihan atau transformasi data yang perlu dilakukan sebelum analisis lebih lanjut.

1. Released Year

```
df['Released_Year'] = pd.to_numeric(df['Released_Year'], errors='coerce')
df['Released_Year'] = df['Released_Year'].astype('Int64')
```

Perintah di atas ini merupakan perintah untuk mengubah tipe data menjadi numerik. Hal ini dilakukan karena pada kolom `Released_Year` merupakan kolom yang berisi tahun rilis suatu film, yang mana seharusnya tipe data di dalam kolom ini adalah numerik karena berisikan angka numerik.

```
df['Released_Year'].head()
```

Perintah ini digunakan untuk melihat 5 data pertama dari kolom `Released_Year`.

```
...
      Released_Year
0      1994
1      1972
2      2008
3      1974
4      1957
dtype: Int64
```

Gambar 32 Data Type Released Year

Dari output tersebut dapat diketahui bahwa tipe data berhasil diubah menjadi bentuk numerik.

2. Runtime

```
df['Runtime'] = df['Runtime'].str.replace(' min', '')
df['Runtime'] = pd.to_numeric(df['Runtime'], errors='coerce')
df['Runtime'] = df['Runtime'].astype('Int64')
```

Perintah di atas merupakan perintah untuk menghapus kata "min" agar hanya tersisa angka saja pada kolom Runtime. Hal ini dilakukan agar setelah memasukkan kode untuk mengubah tipe data menjadi bentuk numerik, data tidak hilang atau data yang muncul adalah Nan atau . Sehingga agar kolom Runtime dapat di ubah tipe data menjadi numerik (karena Runtime adalah durasi waktu) maka dihapuslah kata min agar data masih bisa terbaca.

```
df['Runtime'].head()
```

Perintah ini digunakan untuk melihat 5 data pertama dari kolom Runtime.

```
...
```

	Runtime
0	142
1	175
2	152
3	202
4	96

dtype: Int64

Gambar 33 Data Type Runtime

Dari output tersebut dapat diketahui bahwa tipe data berhasil diubah menjadi bentuk numerik.

4. Gross

```
df['Gross'] = df['Gross'].str.replace(',', '')
df['Gross'] = pd.to_numeric(df['Gross'], errors='coerce')
df['Gross'] = df['Gross'].astype('Int64')
```

Perintah di atas merupakan perintah untuk menghapus koma agar hanya tersisa angka saja pada kolom Gross. Sama seperti sebelumnya, Hal ini dilakukan agar setelah memasukkan kode untuk mengubah tipe data menjadi bentuk numerik, data tidak hilang atau data yang muncul adalah Nan. Sehingga agar kolom Gross dapat di ubah tipe data menjadi numerik (karena Gross adalah hasil penjualan film) maka dihapuslah tanda koma agar data bersih dan bisa terbaca. Selain itu adanya tanda koma itu dianggap teks/string.

```
df['Gross'].head()
```

Perintah ini digunakan untuk melihat 5 data pertama dari kolom Gross.

	Gross
0	28341469
1	134966411
2	534858444
3	57300000
4	4360000

dtype: Int64

Gambar 34 Data Type Gross

Dari output tersebut dapat diketahui bahwa tipe data berhasil diubah menjadi bentuk numerik.

2.3.2 Inconsistent Values

Inconsistent values adalah kondisi ketika data dalam suatu kolom memiliki format atau penulisan yang tidak konsisten. Hal ini dapat terjadi karena perbedaan cara penulisan, kesalahan input data, atau perbedaan format data. Nilai yang tidak konsisten dapat menyulitkan proses analisis sehingga perlu diperiksa dan diperbaiki pada tahap *data preparation* agar data menjadi lebih seragam dan mudah dianalisis.

```
df['Certificate'] = df['Certificate'].replace({
    'U/A': 'UA',
    'G': 'U',
    'TV-MA': 'A',
    'R': 'A',
    '16': 'PG-13',
    'TV-14': 'PG-13',
    'Passed': 'Unrated',
    'Approved': 'Unrated',
    'GP': 'Unrated'
})
```

```
for col in ['Certificate']:
    print(df[col].unique())
```

Perintah di atas merupakan perintah untuk penanganan pada kolom certificate yang tidak konsisten. Inconsistent Values pada kolom ini disebabkan oleh pencampuran berbagai standar rating film dari negara yang berbeda, seperti standar Amerika (MPA) dengan kode G/PG dan standar India (CBFC) dengan kode U/UA. Selain itu, terdapat masalah redundansi di mana satu kategori yang sama ditulis dengan format berbeda, contohnya penggunaan UA dan U/A yang membuat data terbaca sebagai dua kategori yang berbeda. Perintah di bawah ini diterapkan untuk mengatasi masalah tersebut, yaitu dengan melakukan standarisasi data melalui metode mapping.

```
... ['A' 'UA' 'U' 'PG-13' nan 'PG' 'Unrated' 'TV-PG']
```

Gambar 35 Inconsistent Values Certificate

Setelah dilakukan penanganan pada kolom Certificate, terlihat bahwa jumlah kategori kini menjadi lebih ringkas yang menandakan bahwa data sudah lebih konsisten.

2.3.3 Missing Values

Missing Values merupakan sebuah kondisi dimana data hilang atau tidak terbaca. Sebelumnya telah dilakukan pengecekan terhadap dataset untuk melihat seberapa besar rasio presentase missing values atau data yang hilang.

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])
```

Perintah ini digunakan untuk menghitung persentase nilai kosong (*missing values*) pada setiap kolom dalam dataset. Perhitungan dilakukan dengan membagi jumlah nilai kosong pada setiap kolom dengan total jumlah data, kemudian dikalikan 100 sehingga menghasilkan rasio *null* dalam bentuk persentase. Hasilnya ditampilkan dalam bentuk DataFrame dengan kolom bernama “Null Ratio in %” agar lebih mudah dibaca dan dianalisis.

	Null Ratio in %
Poster_Link	0.0
Series_Title	0.0
Released_Year	0.1
Certificate	10.1
Runtime	0.0
Genre	0.0
IMDB_Rating	0.0
Overview	0.0
Meta_score	15.7
Director	0.0
Star1	0.0
Star2	0.0
Star3	0.0
Star4	0.0
No_of_Votes	0.0
Gross	16.9

Gambar 36 Missing Values


Dari output tersebut terlihat Kolom Gross (16.9%) dan Meta_score (15.7%): Kedua kolom ini memiliki tingkat kehilangan data yang paling tinggi. Hal ini cukup krusial karena Gross berkaitan dengan pendapatan film dan Meta_score berkaitan dengan penilaian kritikus. Tingginya angka ini menunjukkan adanya keterbatasan informasi finansial dan ulasan kritikus pada sumber data asli, sehingga perlu penanganan khusus (seperti pengisian nilai rata-rata atau penghapusan data).

Kolom Certificate (10.1%): Terdapat sekitar 10% data film yang tidak memiliki label rating usia. Hal ini menjelaskan mengapa muncul nilai nan pada output kodingan sebelumnya. Nilai kosong ini kemungkinan besar berasal dari film-film independen atau film internasional yang belum mendapatkan klasifikasi rating resmi. Kolom Released_Year (0.1%): Tingkat kehilangan data di kolom ini sangat kecil.

1. Gross

```
plt.figure(figsize=(10, 6))
sns.histplot(df['Gross'], bins=20, kde=True)
plt.title('Distribusi Gross')
plt.xlabel('Gross')
plt.ylabel('Frekuensi')
plt.show()
```

Perintah ini digunakan untuk memvisualisasikan distribusi nilai pada kolom Gross menggunakan histogram. Grafik ini menunjukkan sebaran nilai pendapatan film (*Gross*) berdasarkan frekuensi kemunculannya, serta dilengkapi dengan garis KDE untuk membantu melihat pola distribusi data secara lebih jelas.



Gambar 37 Distribusi Gross

Melihat distribusi data penduduk di atas, terlihat bahwa distribusi data pendapatan atau gross tidak merata atau cenderung miring ke kanan (*right-skewed*), di mana terdapat banyak nilai ekstrem (*outliers*) dari segelintir film dengan pendapatan yang sangat tinggi. metode imputasi median dipilih sebagai langkah yang paling aman agar nilai pengisi data kosong tidak menyimpang jauh dari karakteristik asli dataset.


```
df['Gross'] = df['Gross'].fillna(df['Gross'].dropna().median())
```

Perintah ini digunakan untuk mengisi nilai kosong (*missing values*) pada kolom Gross dengan nilai median dari kolom tersebut. Median dipilih karena berdasarkan hasil visualisasi histogram, distribusi data cenderung miring ke kanan (*right-skewed*), sehingga median lebih tepat digunakan karena tidak terlalu dipengaruhi oleh nilai ekstrem (*outlier*) dibandingkan rata-rata.

2. Meta_score

```
plt.figure(figsize=(10, 6))
sns.histplot(df['Meta_score'], bins=20, kde=True)
plt.title('Distribusi Meta_score')
plt.xlabel('Meta_score')
plt.ylabel('Frekuensi')
plt.show()
```

Perintah ini digunakan untuk memvisualisasikan distribusi nilai pada kolom Meta_score menggunakan histogram. Grafik ini menampilkan sebaran nilai Meta_score berdasarkan frekuensinya serta dilengkapi dengan garis KDE untuk membantu melihat pola distribusi data secara lebih jelas.



Gambar 38 Distribusi Meta Score

Berdasarkan visualisasi histogram di atas, terlihat bahwa data memiliki distribusi yang cenderung mendekati distribusi normal (simetris), meskipun ada sedikit kemiringan ke kiri (negative skew). Sebagian besar data berkumpul di rentang skor 60 hingga 90, yang menunjukkan bahwa mayoritas film dalam dataset ini memiliki penilaian kritikus yang cukup stabil dan berada pada rentang yang serupa. Karena tidak adanya nilai ekstrem (outliers) yang mencolok seperti pada data pendapatan, maka penggunaan Mean (rata-rata) sebagai metode imputasi.

```
df['Meta_score'] = df['Meta_score'].fillna(df['Meta_score'].dropna().median())
```

Perintah ini digunakan untuk mengisi nilai kosong (missing values) pada kolom Meta_score dengan nilai median dari kolom tersebut. Median dipilih karena distribusi data cenderung tidak simetris sehingga median lebih stabil dan tidak terlalu dipengaruhi oleh nilai ekstrem (outlier).

3. Certificate

```
df = df.drop('Certificate', axis=1)
```

Perintah ini digunakan untuk menghapus kolom Certificate dari dataset. Berdasarkan hasil observasi, ditemukan adanya pola di mana film yang memiliki missing values pada kolom Certificate cenderung juga memiliki missing values pada kolom Gross. Mengingat persentase data yang hilang pada Certificate hanya sekitar 10.1%, diputuskan untuk melakukan penghapusan atau drop. Metode ini dipilih untuk menjaga integritas analisis, penggunaan modus untuk mengisi kolom Certificate sangat dihindari karena berisiko menciptakan bias klasifikasi. Sebagai contoh, film dengan konten dewasa yang datanya hilang dapat secara tidak sengaja terlabeli sebagai film 'Semua Umur' (U) jika mengikuti nilai mayoritas dataset.

```
df = df.drop('Certificate', axis=1)
```

Perintah ini digunakan untuk mengganti nilai 'PG' pada kolom Released_Year menjadi '1995'. Hal ini dilakukan untuk memperbaiki nilai yang hilang pada kolom tahun rilis sehingga data menjadi lebih sesuai dengan format tahun dan dapat dianalisis dengan lebih akurat.

2.3.4 Duplicated Values

Dataset tidak memiliki duplicated values, sehingga tidak diperlukan proses penghapusan atau penanganan data duplikat.

2.3.5 Outliers

Outliers adalah nilai data yang berbeda jauh dari sebagian besar data lainnya dalam suatu dataset. Nilai ini bisa sangat tinggi atau sangat rendah dibandingkan pola umum data, sehingga dapat memengaruhi hasil analisis dan biasanya perlu dideteksi serta ditangani pada tahap data preparation.

...	Kolom	Persentase Outliers
	IMDB_Rating	1.3
	Meta_score	0.7
	No_of_Votes	6.7

Gambar 39 Outliers

1. Gross

Ditemukan persentase outliers sebesar 12.5% pada kolom pendapatan, namun diputuskan untuk tetap menggunakan data asli dengan mengabaikan nilai outliers. Alasannya, nilai pendapatan yang sangat tinggi merupakan bukti nyata kesuksesan film yang menjadi target utama industri, sehingga menghapus data ini akan menghilangkan wawasan krusial mengenai potensi keuntungan maksimal yang bisa dicapai oleh sebuah formula film.

2. No_of_votes

Ditemukan persentase outliers sebesar 6.7% yang mencerminkan tingkat keterlibatan massa yang luar biasa, sehingga diputuskan untuk mengabaikan nilai outliers ini. Hal ini dilakukan untuk menjaga integritas data mengenai popularitas film-film legendaris, agar industri dapat mengukur sejauh mana sebuah karya mampu menarik perhatian penonton secara masif tanpa adanya pemotongan data.

3. Meta_score

Persentase outliers pada kolom ini sebesar 3,1%, sehingga tindakan yang diambil adalah membiarkan data dengan mengabaikan nilai outliersnya. Hal ini dilakukan karena rentang nilai skor kritik (0-100) sudah bersifat stabil secara alami, sehingga data asli tetap digunakan guna menjamin perbandingan yang akurat antara selera pasar dengan penilaian teknis dari para kritikus profesional.

4. Runtime

Persentase outliers sebesar 2,9% pada durasi film yang sangat panjang, dan terhadap kolom ini dilakukan penanganan imputasi dengan metode capping. Alasannya adalah untuk menormalisasi durasi yang terlalu ekstrim agar tidak merusak perhitungan rata-

rata durasi ideal, sehingga hasil analisis dapat memberikan rekomendasi durasi yang lebih efisien secara biaya produksi dan nyaman bagi penonton bioskop umum.

5. IMDb_Rating

Kolom ini memiliki persentase outliers sebesar 1,3%, dan terhadap data tersebut akan membiarkannya dengan mengabaikan nilai outliers . Karena tujuan bisnis adalah mengidentifikasi karakteristik film yang paling disukai audiens, maka nilai rating yang sangat tinggi merupakan objek penelitian utama yang valid untuk melihat standar kepuasan penonton tertinggi.

6. Released_Year

Ditemukan persentase outliers sebesar 0,7% yang merepresentasikan film-film dari era klasik. Terhadap data ini, diputuskan untuk mempertahankan data asli dengan mengabaikan nilai outliers guna menjaga histori kesuksesan film lintas zaman, sehingga industri dapat mempelajari apakah elemen daya tarik film lama masih relevan dengan selera penonton modern.

```
columns_to_impute = ["Runtime"]

for col in columns_to_impute:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

    df.loc[:, col] = df[col].clip(lower=lower_bound, upper=upper_bound)
```

Perintah di atas merupakan perintah untuk melakukan metode capping pada kolom runtime guna menormalisasi durasi yang terlalu ekstrim agar tidak merusak perhitungan rata-rata durasi ideal, sehingga hasil analisis dapat memberikan rekomendasi durasi yang lebih efisien secara biaya produksi dan nyaman bagi penonton bioskop umum.

2.3.6 Data Construction

Construct data merupakan kegiatan untuk menciptakan fitur (features) baru dari data yang ada maupun mengubah data agar sesuai dengan kebutuhan analisis atau data mining yang akan digunakan.

1. Genre

Pada dataset asli, kolom Genre memiliki format multi-label (satu film memiliki beberapa genre sekaligus). Untuk mempermudah analisis preferensi penonton secara spesifik, dilakukan konstruksi data dengan mengekstraksi genre pertama sebagai Main_Genre. Hal ini didasarkan pada asumsi industri bahwa genre yang disebutkan pertama merupakan representasi klasifikasi utama dari sebuah film, sehingga memudahkan dalam pemetaan korelasi antara genre dominan terhadap kesuksesan komersial (Gross) dan tingkat kepuasan penonton (IMDB_Rating)

```
df['Main Genre'] = df['Genre'].apply(lambda x: x.split(',')[0].strip())
```

Perintah di atas merupakan perintah untuk melakukan ekstrasi genre pertama sebagai main genre. Dugunakan elemen pertama dari list hasil genre untuk dijadikan main genre.

df

Perintah tersebut digunakan untuk menampilkan beberapa baris pertama dari dataset yang tersimpan di dalam df.

[illegible]

Gambar 40 Tampilan Dataset

Terlihat Gambar di atas terdapat kolom baru yaitu Main_Genre.

2.3.7 Data Reduction

Data Reduction merupakan metode yang digunakan dalam data mining untuk mengurangi ukuran dataset tetapi dengan tetap menjaga informasi penting.

1. Poster Film

Kolom ini dihapus karena hanya berisi URL gambar poster film yang merupakan data tidak terstruktur. Informasi ini tidak memiliki nilai numerik atau kategorikal yang dapat diolah untuk mencari korelasi terhadap kesuksesan finansial maupun kualitas sebuah film.

2. Genre

Kolom Genre asli dihapus karena telah dilakukan proses Data Construction menjadi variabel Main_Genre. Reduksi ini bertujuan untuk menghilangkan redundansi data dan memastikan bahwa setiap entitas film hanya memiliki satu klasifikasi genre tunggal yang konsisten, sehingga mempermudah proses visualisasi dan perbandingan antar kategori.

3. Overview

Kolom ini berisi sinopsis atau ringkasan alur cerita film dalam format teks naratif. Karena analisis ini berfokus pada statistik deskriptif dan pola keberhasilan industri, data tekstual yang sangat panjang ini dihapus karena tidak memberikan metrik kuantitatif yang relevan.

4. Star2, Star3, Star4


Ketiga kolom ini dihapus untuk menyederhanakan analisis pengaruh aktor terhadap kesuksesan film. Dengan memfokuskan data hanya pada aktor utama (Star1), kita dapat melakukan segmentasi Star Power yang lebih bersih dan menghindari tumpang tindih data aktor pendukung yang jumlahnya terlalu banyak untuk dipetakan secara efektif.

```
df = df.drop(['Poster_Link', 'Genre', 'Overview', 'Star2', 'Star3', 'Star4'], axis=1)
```

Perintah di atas merupakan instruksi untuk menghapus kolom sekaligus dalam sebuah DataFrame.

df

Perintah tersebut digunakan untuk menampilkan beberapa baris pertama dari dataset yang tersimpan di dalam df.



	Series_title	Released_Year	Runtime	IMDb_Rating	Meta_score	Director	Star1	No_of_Votes	Gross	Main_Genre
0	The Shawshank Redemption	1994	142	9.3	80.0	Frank Darabont	Tim Robbins	2343110	28341469	Drama
1	The Godfather	1972	175	9.2	100.0	Francis Ford Coppola	Marlon Brando	1620367	134956411	Crime
2	The Dark Knight	2008	152	9.0	84.0	Christopher Nolan	Christian Bale	2303232	534858444	Action
3	The Godfather: Part II	1974	188	9.0	90.0	Francis Ford Coppola	Al Pacino	1129952	57300000	Crime
4	12 Angry Men	1957	96	9.0	96.0	Sidney Lumet	Henry Fonda	689645	4360000	Crime
...	...	...	...	...	...	...	...	...	...	...
995	Breakfast at Tiffany's	1961	115	7.6	76.0	Blake Edwards	Audrey Hepburn	166544	23530892	Comedy
996	Giant	1956	188	7.6	84.0	George Stevens	Elizabeth Taylor	34075	23530892	Drama
997	From Here to Eternity	1953	118	7.6	85.0	Fred Zinnemann	Burt Lancaster	43374	30500000	Drama
998	Lifeboat	1944	97	7.6	78.0	Alfred Hitchcock	Tallulah Bankhead	26471	23530892	Drama
999	The 39 Steps	1935	86	7.6	93.0	Alfred Hitchcock	Robert Donat	51853	23530892	Crime

1000 rows x 10 columns

Gambar 41 After Data Reduction

Setelah dilakukan data reduction terlihat di atas bahwa sekarang hanya ada 10 kolom tersisa. Ini menunjukkan bahwa data reduction telah berhasil dilakukan. Dengan dataset yang awalnya memiliki banyak variabel kompleks disederhanakan menjadi variabel yang hanya memiliki nilai strategis. Manfaat utama dari langkah ini adalah meningkatkan fokus analisis, di mana kita membuang 'kebisingan' (noise) dari data tidak terstruktur seperti URL poster dan sinopsis film yang tidak bisa dihitung secara statistik. Selain itu, reduksi data berfungsi untuk menghindari redundansi, seperti menghapus kolom Genre asli yang sudah diwakili oleh Main_Genre.

BAB III

PENUTUP

3.1 Kesimpulan

Berdasarkan analisis yang telah dilakukan terhadap dataset IMDb Top 1000 menggunakan pendekatan analitik dan visualisasi data, dapat disimpulkan beberapa hal sebagai berikut. Pertama, aktor dengan basis penggemar yang besar seperti Leonardo DiCaprio, Tom Hanks, dan Christian Bale terbukti mendominasi jumlah vote tertinggi, yang mengindikasikan bahwa pemilihan pemeran utama berpengaruh signifikan terhadap tingkat popularitas sebuah film. Kedua, genre Drama merupakan genre yang paling banyak terdapat dalam dataset dengan 289 film, diikuti oleh Action dan Comedy, yang menunjukkan bahwa penonton cenderung lebih mengapresiasi film dengan narasi yang kuat dan mendalam. Ketiga, mayoritas film dalam dataset memiliki durasi antara 94 hingga 126 menit, yang mencerminkan durasi ideal yang paling banyak diproduksi dan diterima oleh penonton secara umum. Keempat, tren rata-rata rating IMDb dari tahun 1980 hingga 2020 menunjukkan kestabilan di kisaran 7,9 hingga 8,1, yang membuktikan bahwa film-film berkualitas tinggi secara konsisten mendapatkan penilaian yang baik dari penonton lintas generasi.

Secara keseluruhan, analisis ini membuktikan bahwa keberhasilan sebuah film dipengaruhi oleh kombinasi faktor seperti pemilihan aktor, genre, dan durasi yang tepat. Hasil analisis ini diharapkan dapat menjadi referensi berbasis data bagi industri perfilman dalam merancang strategi produksi yang lebih efektif dan sesuai dengan preferensi pasar.

3.2 Saran

Berdasarkan hasil analisis, disarankan bagi industri perfilman untuk mempertimbangkan pemilihan aktor dengan basis penggemar yang besar, mengutamakan produksi genre Drama dan Action, serta mempertahankan durasi film di kisaran 90 hingga 130 menit agar lebih mudah diterima pasar. Selain itu, kualitas cerita dan produksi tetap perlu dijaga sebagai prioritas utama mengingat standar rating penonton yang konsisten selama lebih dari empat dekade. Untuk penelitian selanjutnya, disarankan agar menggunakan dataset yang lebih baru dengan variabel yang lebih beragam guna menghasilkan analisis yang lebih komprehensif.

